

汇报顺序与差距分析

一、推荐讲解顺序（跟着代码数据流走）

第 1 步：入口 — 怎么开始的（1 分钟）

讲 `main.py`

- FastAPI 服务启动，端口 8081
- 加载 `.env` 中的 `DEEPSEEK_API_KEY`、`DEEPSEEK_BASE_URL`、`DEEPSEEK_MODEL`
- 挂载 `routes.py` 路由，托管 `static/index.html` 前端

一句话：用户请求从这里进来。

第 2 步：接口 — 有哪些端点（1 分钟）

讲 `routes.py`

- 15 个 REST 端点，重点讲 `/api/v1/evaluate`（单条评估）
- 其他端点提一下名字：`stability` / `calibrate` / `metrics` / `debias` / `report` / `batch` / `history`

一句话：路由层把请求转给引擎。

第 3 步：数据结构 — 输入输出长什么样（1 分钟）

讲 `models.py`

- `EvalRequest`：输入（前后文本 + Profile + human_label + stabilize 标志）
- `EvalResponse`：输出（维度分数 + 瑕疵列表 + verdict + 令牌 + 置信度）

一句话：先让用户知道进去什么、出来什么。

第 4 步：核心引擎 — 怎么评估的（12 分钟，重点）

讲 `chain.py`，按执行顺序拆成 6 个小节：

4.1 文本对齐 — `build_anchored_text()`（2 分钟）

- 前后文本按段落拆分
- 用 `difflib.SequenceMatcher`（阈值 0.4）匹配新旧段落
- 加上 `[Before N]`/`[After N]` 锚点标记
- 这就是“锚点级定位”的基础

4.2 规则引擎瑕疵检测 — `detect_flaws()`（2 分钟）

- 确定性检测，不依赖 LLM，保证关键瑕疵不遗漏

- 三类检测：
 - **数值变化**：字符级 diff，变化幅度 > 10% 自动标记为 critical
 - **结构丢失**：Markdown 表格行/列、列表层级检测
 - **段落删除**：新旧段落匹配率 < 0.4 判定为删除

4.3 Prompt 构建 (2 分钟)

- 转到 `prompts.py`：System Prompt 定义 4 维度评分规则（语义 0.35 / 事实 0.35 / 结构 0.15 / 可读性 0.15）
- `build_system_prompt(profile)`：基础规则 + Profile 补充 + Few-Shot + 抗偏置指令
- 转到 `profiles.py` 讲三种 Profile 的区别（通用 / 政府公告 / 法律文书）

4.4 LLM 调用 + JSON 解析 (1 分钟)

- `create_llm()` 创建 DeepSeek 单例实例
- 三层 JSON 兜底解析：直接解析 → Markdown 围栏提取 → 正则花括号提取
- 应对 DeepSeek 偶发的 `<think>` 标签输出

4.5 后处理 — 判定逻辑 (3 分钟，最关键)

- `apply_soft_penalty()`：取所有瑕疵中最严惩罚因子，不叠加
- `determine_verdict()`：pass ≥ 0.82 / review ≥ 0.5 / fail < 0.5（0.78-0.82 缓冲区默认 review）
- **临界区重采样**：评分落在 0.75-0.85 时自动多跑 2 次取平均
- `apply_profile_penalties()`：从原文提取关键事实（日期/数字/范围），检查是否在治理后消失

4.6 附加信息 (1 分钟)

- `compute_confidence()`：三因子加权置信度
- `compute_risk_level()`：high / medium / low
- `compute_reproducibility_token()`：SHA256 可复现令牌

一句话总结：规则引擎先扫一遍确定性瑕疵，LLM 再做语义判断，后处理合并出最终判定。

第 5 步：验证体系 — 怎么证明裁判可信 (10 分钟，研究亮点)

5.1 一致性校准 — `calibration.py` (3 分钟)

- 在 34 条人工标注数据上对比 LLM 评分与人工评分
- 计算 5 项指标：Pearson r / Spearman ρ / MAE / RMSE / 一致率
- 展示迭代调优过程：0.61 → 0.72 → 0.78 → ≥ 0.8
- 偏差归因方法：逐条分析高偏差样本，归纳三类问题，定向修改 Prompt

5.2 评分稳定性 — `stability.py` (2 分钟)

- 同一输入跑 N 次（temperature=0.0），算方差
- 判定标准：方差 < 0.005 为稳定
- 瑕疵投票机制：按 (类别, 片段前30字符) 分组，多数投票决定严重程度

5.3 瑕疵检出指标 — `metrics.py` (2 分钟)

- Precision / Recall / F1: 贪心一对一匹配 (按类别)
- 锚点准确率: snippet 重叠 ≥ 4 字符 + start_char 容差 ≤ 10 字符
- 额外指标: Cohen's Kappa、Kendall's W、ROUGE-L、BERTScore

5.4 抗偏置 — `debias.py` (2 分钟)

- 长度偏置检测: 前后文本长度比, < 0.3 高风险
- 位置偏置检测: 瑕疵前后半部分分布, $> 80\%$ 集中 = 偏置
- 抗偏置 Prompt 指令自动注入 (长度无关/位置无关/格式无关/领域无关)
- 偏置缓解得分计算

5.5 分数校准器 — `calibrator.py` (1 分钟)

- 基于金标准数据集 (34 条), 对每个模型拟合线性回归
- 将原始分映射到校准分, 减少模型间差异

一句话总结: 通过一致性校准、稳定性验证、瑕疵指标、抗偏置四层验证, 证明裁判是可信的。

第 6 步: 报告生成 — 怎么汇总 (2 分钟)

讲 `reporter.py`

- `run_full_evaluation()` 串联 7 大模块:

评估 → 校准 → 稳定性 → 瑕疵指标 → 锚点准确率 → 偏置分析 → 可复现性
↓
I1-I8 验收标准逐项检查

- 输出完整验收报告, 包含所有指标和 Pass/Fail 判定

一句话: 一键跑完所有验证, 生成完整报告。

第 7 步: 批量与存储 (1 分钟, 快速带过)

- `batch.py`: 异步并发 (Semaphore 5) + SHA256 缓存 + 指数退避重试
- `storage.py`: JSONL 历史持久化, 支持按 request_id 或令牌查询
- `calibrator.py`: 基于金标准数据的分数校准

第 8 步: 模型适配 (1 分钟, 可选讲)

- `protocol.py`: 抽象接口 `EvaluationProtocol`
- `adapters.py`: 三个适配器 (DeepSeek / MIMO / GPT)
- `model_registry.py`: 注册中心, 支持 `evaluate_all()` 切换对比

第 9 步：测试（1 分钟，快速带过）

- 端到端测试（P6-1）：API → LLM → 解析 → 渲染 全链路通过
- 边界测试（P6-2）：空文本 / 超长 / 特殊字符 / 中英混合 全通过
- 异常测试（P6-3）：API Key 错误 / 超时 / JSON 畸形 全通过

二、时间分配建议（30 分钟汇报）

步骤	模块	时间	重点程度
1-3	入口 + 接口 + 数据结构	3 分钟	了解即可
4	核心引擎（chain.py）	12 分钟	重点讲
5	验证体系（4 个模块）	10 分钟	研究亮点
6	报告生成	2 分钟	快速带过
7-9	批量 + 模型 + 测试	3 分钟	可选

核心思路：先让老师看到完整链路能跑通（第 4 步），再证明裁判是可信的（第 5 步）。

三、对照课题要求的完成情况

3.1 核心能力对照

课题要求	对应实现	状态	说明
语义一致性评估	prompts.py 语义一致性维度（权重 0.35）+ chain.py 评分逻辑	✅ 已完成	4 维度加权评分
过度清洗/误改识别	chain.py 的 detect_flaws() + LLM 识别	✅ 已完成	规则引擎 + LLM 双通道
可读性与结构质量评估	prompts.py 结构完整性（0.15）+ 可读性（0.15）	✅ 已完成	含 Markdown 表格/列表检测
锚点级瑕疵定位	chain.py 的 build_anchored_text() + metrics.py 的 compute_anchor_accuracy()	✅ 已完成	字符级定位 + 准确率计算
评分稳定性与可解释性	stability.py 多次采样 + 每维度 reason + 每瑕疵 description	✅ 已完成	方差 < 0.005
评分稳定化（多次采样/投票）	stability.py 的 run_stability() + 瑕疵投票	✅ 已完成	多数投票 + 临界区重采样
与人工标注的一致性校准	calibration.py 的 calibrate()	✅ 已完成	Pearson r ≥ 0.8
抗位置/长度偏差	debias.py 的 4 项检测	✅ 已完成	自动注入抗偏置指令

3.2 技术指标对照

指标项	目标值	当前状态	差距
与人工一致性	相关性 ≥ 0.8	✅ Pearson $r \geq 0.8$	无
评分稳定性	方差足够小	✅ 方差 < 0.005	无
瑕疵检出	$F1 \geq 0.8$	⚠️ 已实现，未明确报告 F1 数值	需跑一次完整测试确认
可解释性	理由可被人工复核	✅ 每维度 reason + 每瑕疵 description	无
瑕疵可定位	定位准确率 $\geq 90\%$	⚠️ 已实现，未明确报告准确率数值	需跑一次完整测试确认
可复现	固定策略可复现	✅ SHA256 令牌	无

3.3 交付物对照

课题要求的交付物	当前状态	说明
可运行的评估智能体一套	✅ 已完成	FastAPI + Streamlit + HTML 前端
对外暴露标准接口	✅ 已完成	15 个 REST 端点
输入前后文本对	✅ 已完成	EvalRequest
输出评分与瑕疵清单	✅ 已完成	EvalResponse
评测集	✅ 已完成	eval_dataset.json (34 条) + gold_dataset_v1.json (34 条)
示例数据	✅ 已完成	数据集中含多种场景样本

四、不足之处与改进建议

4.1 需要补的硬指标

不足	说明	建议
瑕疵检出 F1 未明确报告	课题要求 $F1 \geq 0.8$ ，代码已实现但没有跑出具体数值	用 metrics.py 对 eval_dataset 跑一次完整的 P/R/F1，记录数值
锚点准确率未明确报告	课题要求 $\geq 90\%$ ，代码已实现但没有跑出具体数值	用 compute_anchor_accuracy() 跑一次，记录准确率
缺少 F1 和锚点准确率的验收截图/数据	汇报时需要拿出具体数字	跑完后截图或导出报告，作为汇报证据

4.2 测试覆盖不足

不足	说明	建议
测试用例偏少	<code>test_day6_minimal.py</code> 只有 6 个测试	补充核心模块的单元测试（ <code>chain.py</code> 的各函数）
未覆盖 Profile 差异化测试	三种 Profile 的评分差异未被验证	补充测试：同一输入在不同 Profile 下的评分对比
未覆盖多模型对比测试	DeepSeek / Mimo / GPT 的一致性未验证	如果老师问到，说明这是扩展功能

4.3 文档与演示

不足	说明	建议
缺少 PPT	课题要求 PPT + 演讲脚本 + Demo	Day 8-9 制作
缺少 Demo 视频	课题要求可演示	录制一次完整的评估流程演示
缺少 API 使用文档	质检流水线集成需要文档	写一份简要的 API 调用指南
README 不完整	项目根目录缺少完整的 README	补充项目介绍、安装步骤、使用说明

4.4 功能层面可改进

不足	说明	建议
评估 Profile 只有 3 个	可扩展更多场景（医疗、金融、教育等）	作为后续扩展说明，不影响验收
金标准数据集只有 34 条	样本量偏小，校准结果可能不够稳健	说明数据集构建过程（54→34 去重），强调标注质量
缺少与人工的实时校准反馈	当前是离线校准，不能在线修正	可作为后续优化方向
未做模型间一致性对比	多模型适配已实现，但未对比不同模型的评分差异	用 <code>evaluate_all()</code> 跑一次对比，可作为附加亮点

4.5 汇报时可能被问到的问题

问题	建议回答方向
"34 条数据够吗？"	强调去重过程（54→34），每条都是精细标注，覆盖三类场景；后续可扩展
"F1 具体多少？"	跑一次完整测试，拿到真实数据
"和 GPT 比 DeepSeek 好在哪？"	用 <code>evaluate_all()</code> 跑一次对比，展示差异
"怎么保证不是过拟合 Prompt？"	强调规则引擎 + LLM 双通道，规则引擎是确定性的

问题	建议回答方向
"临界区重采样会不会太慢？"	只有 0.75-0.85 的边界分才触发，大部分样本不触发
"Profile 的实际效果差异？"	跑同一输入在 general / government / legal 下的对比

五、验收前 Checklist

- ☐ 跑一次完整的 F1 测试，记录数值（目标 ≥ 0.8 ）
- ☐ 跑一次完整的锚点准确率测试，记录数值（目标 $\geq 90\%$ ）
- ☐ 截图保存校准报告（Pearson $r \geq 0.8$ 的证据）
- ☐ 截图保存稳定性报告（方差 < 0.005 的证据）
- ☐ 准备 1-2 个完整的评估示例（输入 $\rightarrow$ 输出全链路）
- ☐ 准备好被问到 F1 / 锚点准确率 / 数据集大小 / Profile 效果时的回答