

大模型内容安全与质量评估智能体 · 研发日报

日期	2026年6月29日（周一）
课题	内容保真度与治理质量评估智能体（LLM-as-Judge）
阶段	Phase 3 — Prompt 调优与多轮校准验证
日报编号	Day 2 / 10
组长	李首澎
组员	阿思晗、由靖喆

一、组员进度汇报

1.1 组员：阿思晗

今日任务：大模型 Prompt 调试 + 自校准模型验证

今日主要围绕 Day 1 首轮校准结果中暴露出的偏差问题展开工作。首先对高偏差样本逐条复盘，将模型误判原因归纳为三类：关键数值变化识别不敏感、格式优化场景误扣分、过度清洗问题识别偏轻。在此基础上，对现有评分 Prompt 进行了定向调试，重点补强了数值敏感性约束、格式豁免说明和大段删减的严重程度描述。

在 Prompt 调整完成后，继续结合现有测试样本开展了第二轮校准验证，并对人工标注样本进行了对照检查，确保测试集标注与当前评分逻辑保持一致。结果表明本轮优化方向有效，模型评分与人工标注的一致性较首轮有明显改善。针对第二轮中仍存在轻微波动的边界样本，继续补充了判定边界规则，并再次验证，进一步提升了评分的稳定性。

任务	完成状态
高偏差样本复盘与原因分类	✅ 已完成
大模型 Prompt 定向调试（数值敏感性 + 格式豁免 + 过度清洗）	✅ 已完成
第二轮校准验证与测试样本对照检查	✅ 已完成
边界样本规则补强与再验证	✅ 已完成

计划工时：4h 实际工时：约 3.5h 偏差：提前约 0.5h

1.2 组员：由靖喆

今日任务：前端质检看板开发跟进 + 系统 API 联调测试 + 技术文档整理

今日协助跟进前端质检看板与后端接口的联调工作，重点对接了评估结果返回格式与前端渲染逻辑之间的数据映射关系，确认瑕疵列表中的字段结构符合前端高亮渲染的要求。同时对系统 API 的调用情况进行了联调测

试，初步梳理了异常请求的分布情况，并同步整理了相关技术说明内容，为后续边界测试和技术文档完善提供参考依据。

任务	完成状态
前端质检看板数据映射确认	✅ 已完成
系统 API 联调测试与异常记录整理	✅ 已完成
技术文档补充整理	✅ 已完成

计划工时：2h 实际工时：约 2h 偏差：持平

二、组长汇总

2.1 今日整体进度说明

根据研发计划书安排，Day 2 的主要任务是围绕 **Prompt 调优与多轮校准验证** 展开。在 Day 1 中，已完成评估数据集的扩充与人工标注，并基于现有数据完成了首轮一致性校准测试。首轮校准结果表明，当前系统已具备基本的自动评分能力，但在模型评分与人工评分的一致性方面仍有提升空间，尤其是个别高偏差样本中模型判断与人工标注之间存在较明显差异。

今日组员阿思晗按计划完成了大模型 Prompt 调试、自校准验证与测试样本对照工作，优化方向清晰，验证结果表明调试有效；组员由靖喆完成了前端质检看板开发跟进、系统 API 联调测试及技术文档整理，为后续集成测试做好准备。整体推进节奏正常，各成员任务均已完成。

2.2 组员任务完成情况汇总

姓名	今日任务	完成状态	备注
阿思晗	大模型 Prompt 调试 + 自校准模型验证 + 测试样本对照	✅ 全部完成	提前 0.5h 完成
由靖喆	前端质检看板开发跟进 + 系统 API 联调测试 + 技术文档整理	✅ 全部完成	按时完成
李首澎（组长）	系统架构统筹 + 对齐引擎与集成评审	✅ 全部完成	见下节

2.3 组长今日工作内容

今日作为组长，主要承担以下统筹与技术评审工作：

- 系统架构统筹：**结合 Day 2 的调优任务，确认当前评估流程、校准流程与前端联调流程之间的衔接关系，保证整体开发节奏与开题报告中既定的系统架构方向一致。
- 底层对齐逻辑评审：**与阿思晗一起对首轮校准高偏差样本进行逐条复盘，确认偏差归因的合理性，重点检查底层评分规则与对齐逻辑是否存在偏差累积问题，确保后续调优建立在正确的判断基础上。
- 核心模块集成审查：**在阿思晗完成规则补强后，对调优内容进行审查，重点核查新增规则是否与现有评分框架存在逻辑矛盾，以及校准流程与整体系统集成是否保持一致。

4. **联调协调与进度推进**：跟进由靖喆负责的前端质检看板与 API 联调情况，确认数据格式对齐、接口调用顺畅，确保前后端工作线不产生阻塞。

计划工时：6h 实际工时：约 5.5h 偏差：提前约 0.5h

三、今日研发过程记录

3.1 高偏差样本分析

今天首先完成了对首轮校准高偏差样本的集中复盘。分析结果显示，当前模型误判主要集中在以下三类场景：

偏差类型	具体表现	初步原因
数值敏感性不足	对金额、比例、数量级误改扣分不够	Prompt 对关键数值变化的严重性强调不强
格式优化误罚	把标点、空格、换行调整误认为语义变动	缺少明确的格式豁免说明
过度清洗识别不足	对大段删除、信息压缩过度的问题处罚偏轻	对结构性删减的严重程度约束偏弱

通过这一步，把原本比较模糊的"模型评分不够贴近人工判断"进一步拆解成几个具体问题，为后续调优提供明确方向。

3.2 Prompt 调优的主要方向

在问题分析完成后，今天重点从以下几个方面对评分规则进行了优化：

(1) 强化关键数值类问题的判定

对金额、比例、年份、数量级等涉及事实准确性的内容进一步提高敏感度，要求模型优先检查这类信息是否发生变化，并在出现明显误改时给出更严格的处罚判断。

(2) 增加格式性调整的豁免规则

针对纯标点规范、空格调整、换行优化、段落对齐等治理操作，明确其属于形式层面的整理，不应被误判为语义变化，从而减少不必要的扣分。

(3) 提高过度清洗场景的严重程度

对于整段内容被删除、压缩后丢失关键信息、文本结构被明显削弱等情况，在规则中补强其严重等级，使模型能够更准确识别"内容保真度受损"的场景。

(4) 细化"合理改写"与"错误改写"的边界

通过补充边界定义，让模型更清楚哪些变化属于表达优化，哪些变化已经实质影响原文含义，从而提升相似样本之间的判断一致性。

3.3 多轮验证过程

在完成上述调优之后，继续开展了多轮校准验证，以确认优化不是偶然生效，而是能够在整体样本上持续发挥作用。整个验证过程大致分为两个阶段：

- **第一阶段：**完成第一轮调优后重新校准，观察结果是否比 Day 1 首轮测试更接近人工评分；
- **第二阶段：**针对仍存在波动的边界样本继续补充规则，再次开展验证，进一步提升规则稳定性。

这一过程说明，今日工作并不是"一次修改、一次测试"的简单线性过程，而是一个不断发现问题、修正规则、再用数据验证的循环过程，也更加符合实际研发中 Prompt 调优的典型特点。

四、关键产出

产出内容	说明
高偏差样本问题分类结果	归纳为数值敏感性不足、格式误罚、过度清洗识别偏弱三类
优化后的评分规则方向	在双维度评分框架不变的基础上，对提示规则进行了细化补强
多轮校准验证结果记录	确认调优方向有效，优化持续发挥作用而非偶发
前端联调数据格式确认	确保瑕疵字段结构与前端高亮渲染逻辑对齐

五、当前进度评估

5.1 里程碑进度看板

里程碑	完成标志	目标日	当前状态	风险等级
M1: 校准达标	Pearson $r \geq 0.8$	Day 2	 调优中，已有明显改善	 中
M2: 指标全达标	F1 / 锚点 / 偏置 通过	Day 5	 未开始	 低
M3: 集成测试通过	全流程无 Bug	Day 6	 未开始	 低
M4: 演示材料完备	PPT + 脚本 + Demo 就绪	Day 9	 未开始	 低
M5: 最终提交	全部材料打包提交	Day 10	 未开始	 低

5.2 总体进度状态

当前状态：正常推进，节奏稳定。

Day 2 全部任务按计划完成，组员阿思晗完成了 Prompt 调优与多轮校准验证，调优方向经验证有效；组员由靖喆完成了前端联调跟进与日志整理工作。两条工作线推进顺畅，未出现阻塞。M1 校准达标指标已有明显改善，预计通过持续优化可在计划节点内完成。

六、后续安排

后续工作将继续围绕评估结果的可靠性展开，重点转向模型在不同文本长度、不同瑕疵位置以及重复调用条件下是否仍能保持稳定的判断表现。后续不再只关注"能不能打分"，而是进一步验证"打出来的分数是否稳定、是否公平、是否具备一致性"。同时，前端看板的联调工作也将持续跟进，确保评估结果可以完整渲染展示。

七、总结

今天的工作主要围绕首轮校准中暴露出的偏差问题展开，重点完成了高偏差样本分析、评分规则补强以及多轮校准验证。与 Day 1 相比，今日更加体现出研发过程中的迭代特征，即通过复盘发现问题，通过规则调整缩小偏差，再通过新一轮校准结果验证优化是否有效。

全组成员今日均按计划完成各自任务，整体进度正常，团队协作顺畅。系统在数值敏感性、格式优化豁免、过度清洗识别等方面的判断逻辑得到了进一步完善，为后续偏置分析与稳定性验证奠定了较好的基础。