

大模型内容安全与质量评估智能体 · 研发日报

日期	2026年6月30日（周一）
课题	内容保真度与治理质量评估智能体（LLM-as-Judge）
阶段	Phase 2 — 抗偏置与稳定性保障 + Phase 3 — 瑕疵检出与锚点定位
日报编号	Day 3 / 10
组长	李首澎
组员	阿思晗、由靖喆

一、组员进度汇报

1.1 组员：阿思晗

今日任务：偏置检测模块实现 + 评估 Profile 系统开发

今日围绕偏置检测和评估 Profile 系统展开辅助开发工作。

上午在 `app/debias.py` 中实现了四项偏置检测功能：长度偏置检测（P2-1，计算治理前后文本长度比，标记 High/Medium/Low 风险等级）、位置偏置检测（P2-2，分析瑕疵分布是否集中在前/后半部分，检测 front_bias/back_bias）、偏置缓解得分计算（P2-3，维度标准差 × 0.5 + 长度因子 × 0.5）和抗偏置 Prompt 补充指令生成（P2-4，长度无关/位置无关/格式无关/领域无关）。

下午完成了评估 Profile 系统（`app/profiles.py`）的开发，实现了 3 个 Profile：general（通用评估）、government_notice_strict（政府公告严格模式，对日期/期限/义务等关键事实提高敏感度）和 legal_strict（法律文书严格模式，对条款引用/权利义务表述提高准确性要求）。每个 Profile 定义了 critical_fact_types 和 penalty_policy，评估时动态调整 Prompt 规则和扣分力度。同时在 `app/metrics.py` 中实现了 BERTScore 文本相似度指标，基于 BERT 词向量计算语义层面的匹配度。

任务	完成状态
P2-1 长度偏置检测（ <code>app/debias.py</code> ）	✅ 已完成
P2-2 位置偏置检测（ <code>app/debias.py</code> ）	✅ 已完成
P2-3 偏置缓解得分计算（ <code>app/debias.py</code> ）	✅ 已完成
P2-4 抗偏置 Prompt 补充指令（ <code>app/debias.py</code> ）	✅ 已完成
评估 Profile 系统（3 个 Profile）	✅ 已完成
BERTScore 文本相似度指标	✅ 已完成

计划工时：4h 实际工时：约 4h 偏差：持平

1.2 组员：由靖喆

今日任务：偏置检测前端展示 + 指标可视化 + 校准脚本联调

今日配合后端开发，完成前端展示和联调工作。

上午在 Streamlit 界面和 `static/index.html` 中增加了偏置分析结果的展示区域，以卡片形式展示长度偏置风险等级、位置偏置说明和偏置缓解得分。下午在前端增加了 F1、Precision、Recall 和 anchor accuracy 的展示区域，并对 `run_calibration.py` 校准脚本进行了联调。

任务	完成状态
偏置分析结果前端展示集成	✅ 已完成
瑕疵检出指标与锚点准确率前端展示	✅ 已完成
<code>run_calibration.py</code> 校准脚本联调	✅ 已完成

计划工时：2h 实际工时：约 2h 偏差：持平

```
python_version > app > debias.py > ...
D:\trae project\shixun\python_version • 包含强调项, after_text: str) -> dict[str, Any]:
21 """
22 len_before: int = len(before_text)
23 len_after: int = len(after_text)
24
25 if len_before == 0 or len_after == 0:
26     return {
27         "len_before": len_before,
28         "len_after": len_after,
29         "length_ratio": 0.0,
30         "bias_risk": "critical",
31         "risk_level": "critical",
32         "description": "输入文本为空, 无法评估",
33         "mitigation": "请提供有效的治理前后文本",
34     }
35
36 ratio: float = len_after / len_before
37
38 if ratio < 0.3:
39     risk = "high"
40     desc: str = f"治理后文本长度仅为治理前的 {ratio*100:.0f}%, 存在过度压缩风险"
41     mitigation = '建议提醒LLM关注语义完整性, 区分"合理精简"与"过度压缩"'
42 elif ratio > 2.0:
43     risk = "medium"
44     desc: str = f"治理后文本长度为治理前的 {ratio*100:.0f}%, 存在过度扩充风险"
45     mitigation = "建议提醒LLM关注新增内容的必要性"
46 elif ratio < 0.6:
47     risk = "medium"
48     desc: str = f"治理后文本长度为治理前的 {ratio*100:.0f}%, 需关注是否存在语义损失"
49     mitigation = "建议在评估时区分结构优化导致的长度变化与语义丢失"
50 else:
51     risk = "low"
52     desc: str = f"治理前后长度比合理 ({ratio:.2f}), 长度偏置风险低"
53     mitigation: None = None
54
55 return {
56     "len_before": len_before,
57     "len_after": len_after,
58     "length_ratio": round(number=ratio, ndigits=4),
59     "bias_risk": risk,
60     "risk_level": risk,
61     "description": desc,
62     "mitigation": mitigation,
63 }
```

二、组长汇总

2.1 今日整体进度说明

根据研发计划书安排, Day 3 对应 Phase 2 (抗偏置与稳定性保障) 和 Phase 3 (评估指标与校准) 的核心开发任务。今日完成了 Phase 2 全部 6 项任务 (P2-1 至 P2-6) 和 Phase 3 的前 3 项任务 (P3-1 至 P3-3), 系统当前已具备完整的偏置检测能力、稳定性验证机制、可复现性令牌、瑕疵检出指标和锚点定位准确率计算能力。

2.2 组员任务完成情况汇总

姓名	今日任务	完成状态	备注
李首澎 (组长)	P2-5 稳定性 + P2-6 可复现令牌 + P3-1/2/3 指标与校准 + Profile 系统设计	✅ 全部完成	核心技术工作

姓名	今日任务	完成状态	备注
阿思晗	P2-1/2/3/4 偏置检测实现 + BERTScore	✅ 全部完成	辅助模块开发
由靖喆	前端展示集成 + 校准脚本联调	✅ 全部完成	按时完成

2.3 组长今日工作内容

今日作为组长和技术负责人，承担了 Phase 2 和 Phase 3 的核心技术开发工作：

- 1. **P2-5 评分稳定性模块**：在 `app/stability.py` 中实现了多次采样分析逻辑，对同一输入执行 $n \geq 3$ 次评估（temperature=0.0），计算均值、方差和标准差，判定标准为方差 < 0.005 。
- 2. **P2-6 可复现性令牌**：在 `app/engine.py` 中实现了基于 SHA256 哈希的可复现令牌生成机制，输入文本 + 模型参数 + Prompt 版本的哈希确保固定策略下结果一致。
- 3. **P3-1 瑕疵检出指标**：在 `app/metrics.py` 中实现了 Precision/Recall/F1 计算，将 LLM 输出的瑕疵列表与 GT 进行比对。
- 4. **P3-2 锚点定位准确率**：实现了字符容差 ≤ 10 字符的锚点匹配算法。
- 5. **P3-3 一致性校准**：在 `app/calibration.py` 中实现了 Pearson r / Spearman ρ / MAE / RMSE / 一致率五项校准指标。
- 6. **评估 Profile 系统设计**：设计了 Profile 注册架构和共享模型基础，确定了 Profile 感知的 Prompt 构建方案。

计划工时：6h 实际工时：约 6h 偏差：持平

```
18     Args:
19         request: 评估请求 (sample_count 控制采样次数)
20         sample_count: 采样次数 (默认 3, 最多 5)
21
22     Returns:
23         StabilityReport: 包含各次采样得分、均值、方差、标准差
24     """
25     from .chain import disable_cache, enable_cache
26
27     # 临时关闭 LLM 响应缓存, 确保每次真实调用 API
28     disable_cache()
29     try:
30         samples: list[dict[str, float]] = []
31         scores: list[float] = []
32
33         for i in range(sample_count):
34             resp: EvalResponse = evaluate(request, temperature=0.0) # 固定低温度保证可复现
35             sample: dict[str, float] = {d.dimension: d.score for d in resp.dimensions}
36             sample["overall"] = resp.overall_score
37             samples.append(sample)
38             scores.append(resp.overall_score)
39         finally:
40             # 无论成功失败, 恢复内存缓存
41             enable_cache(cache_type="memory")
42
43         n: int = len(scores)
44         mean_score: float = sum(scores) / n if n > 0 else 0.0
45         variance: float = sum((s - mean_score) ** 2 for s in scores) / n if n > 0 else 0.0
46         std_dev = variance**0.5
47
48         # 方差阈值: 小于 0.005 视为稳定 (即标准差 < 0.07)
49         is_stable: bool = variance < 0.005
50
51         return StabilityReport(
52             request_id=request.request_id,
53             samples=samples,
54             mean_score=round(number=mean_score, ndigits=4),
55             variance=round(number=variance, ndigits=6),
56             std_dev=round(number=std_dev, ndigits=4),
57             is_stable=is_stable,
58         )
```

三、今日研发过程记录

3.1 Phase 2 — 抗偏置与稳定性保障

P2-1 长度偏置检测

在 `app/debias.py` 中实现了 `detect_length_bias()` 函数, 计算治理前后文本的字符数比值, 当比值超过 1.5 或低于 0.67 时标记为 High 风险, 1.2-1.5 或 0.67-0.83 为 Medium, 其余为 Low。风险等级和说明信息输出到综合报告中。

P2-2 位置偏置检测

实现了 `detect_position_bias()` 函数, 将瑕疵位置按文本前后 50% 分界, 统计前半部分瑕疵占比。当前半部分占比 > 70% 时判定为 `front_bias`, 后半部分占比 > 70% 时判定为 `back_bias`, 否则为 `balanced`。

P2-3 偏置缓解得分

偏置缓解得分 = 维度分数标准差 $\times$ 0.5 + 长度因子 $\times$ 0.5。维度分数标准差越大说明各维度评分越分散（可能受偏置影响），长度因子反映文本长度差异带来的偏置风险。

P2-4 抗偏置 Prompt 补充指令

在 `app/debias.py` 中实现了 `get_debias_instructions()` 函数，返回四类抗偏置指令文本，在 `app/prompts.py` 构建 System Prompt 时自动追加：

- 长度无关：评分不应因文本长短而产生系统性偏差
- 位置无关：瑕疵检出不应受其在文本中位置的影响
- 格式无关：纯格式调整不应被视为语义变更
- 领域无关：评分标准应跨领域保持一致

P2-5 评分稳定性验证

在 `app/stability.py` 中实现了 `run_stability()` 函数，对同一输入执行 n 次评估（默认 $n=3$ ），计算评分的均值、方差和标准差，方差 < 0.005 判定为稳定。

P2-6 可复现性令牌

在 `app/engine.py` 中，对输入文本 + 模型参数 + Prompt 版本进行 SHA256 哈希，生成 `reproducibility_token`。相同输入在固定策略下始终生成相同令牌，支持结果复现和历史查询。

3.2 Phase 3 — 评估指标与校准（P3-1 至 P3-3）

P3-1 瑕疵检出指标

在 `app/metrics.py` 中实现了 `compute_flaw_metrics()` 函数：

- **Precision**：LLM 检出的瑕疵中，有多少与 GT 匹配
- **Recall**：GT 中的瑕疵中，有多少被 LLM 检出
- **F1**：Precision 和 Recall 的调和平均

匹配逻辑基于瑕疵类型（type）和位置（location）的联合判定。

P3-2 锚点定位准确率

实现了 `compute_anchor_accuracy()` 函数，将 LLM 输出的瑕疵位置与 GT 标注进行字符级比对，字符容差 ≤ 10 字符。在容差范围内的匹配计为定位准确，最终输出准确率百分比。

P3-3 一致性校准

在 `app/calibration.py` 中实现了 `calibrate()` 函数，计算五项校准指标：

- Pearson r （线性相关系数）
- Spearman ρ （秩相关系数）
- MAE（平均绝对误差）
- RMSE（均方根误差）

- 一致率（误差 ≤ 0.1 的样本比例）

3.3 额外功能 — 评估 Profile 系统

在完成计划任务的基础上，同步搭建了评估 Profile 系统（[app/profiles.py](#)），旨在支持不同文本类型的差异化评估策略。实现了三个 Profile：

1. **general**：通用评估 Profile，适用于一般性文本治理场景，评分规则为默认配置；
2. **government_notice_strict**：政府公告严格 Profile，针对政府公告类文本提高对日期、期限、义务等关键事实的敏感度，对这类信息的误改施加更严厉的扣分；
3. **legal_strict**：法律文书严格 Profile，针对法律文本提高对条款引用、权利义务表述的准确性要求。

每个 Profile 定义了 `critical_fact_types`（关键事实类型列表）和 `penalty_policy`（处罚策略），在评估时根据当前 Profile 动态调整 Prompt 中的评分规则和扣分力度。Profile 系统与 [app/prompts.py](#) 和 [app/engine.py](#) 已完成对接。

3.4 额外功能 — BERTScore 指标

在 [app/metrics.py](#) 中额外实现了 BERTScore 文本相似度指标。与 ROUGE-L 基于字符匹配不同，BERTScore 基于 BERT 词向量计算语义层面的相似度，能够捕捉同义替换和语序变化等更细粒度的文本差异。该指标用于评估 LLM 生成的瑕疵描述与人工标注之间的语义匹配程度，作为 ROUGE-L 的补充。

```
python_version > app > metrics.py > compute_kappa
234
235
236 def compute_kendalls_w(
237     human_scores: list[float],
238     llm_scores: list[float],
239 ) -> dict[str, float]:
240     """计算 Kendall's W 协和系数（人机排序一致性）。
241
242     衡量两个评分者对样本的排序是否一致。
243     目标: ≥ 0.8
244
245     Args:
246         human_scores: 人工评分列表
247         llm_scores: LLM 评分列表
248
249     Returns:
250         dict 含 kendalls_w, spearman_rho, n_samples
251     """
252     if len(human_scores) != len(llm_scores):
253         raise ValueError("human_scores and llm_scores must have same length")
254
255     n: int = len(human_scores)
256     if n < 2:
257         return {"kendalls_w": 0.0, "spearman_rho": 0.0, "n_samples": n}
258
259     # Kendall's W 对于 2 个评分者简化为:
260     # W = (1 + Spearman_rho) / 2
261     rho, _ = stats.spearmanr(a=human_scores, b=llm_scores)
262     w: Any = (1.0 + rho) / 2.0
263
264     return {
265         "kendalls_w": round(number=float(w), ndigits=4),
266         "spearman_rho": round(number=float(rho), ndigits=4),
267         "n_samples": n,
268     }
269
270
271 def compute_correlation_metrics(
272     human_scores: list[float],
273     llm_scores: list[float],
274 ) -> dict[str, float]:
275     """计算完整的一致性指标集（用于验收报告）。
276
277     包含: Pearson r, Spearman rho, Kappa, Kendall's W, MAE, RMSE
278
```

四、关键产出

产出内容	对应计划任务	说明
app/debias.py 偏置检测模块	P2-1 / P2-2 / P2-3 / P2-4	长度偏置 + 位置偏置 + 缓解得分 + 抗偏置指令
app/stability.py 稳定性验证	P2-5	多次采样 n≥3, 方差 < 0.005
app/engine.py 可复现性令牌	P2-6	SHA256 哈希, 固定策略下结果一致

产出内容	对应计划任务	说明
app/metrics.py 瑕疵检出指标	P3-1	Precision / Recall / F1
app/metrics.py 锚点定位准确率	P3-2	字符容差 ≤ 10 字符匹配
app/calibration.py 一致性校准	P3-3	Pearson / Spearman / MAE / RMSE / 一致率
run_calibration.py 校准脚本联调	P3-3	校准流程端到端验证
前端偏置分析展示	—	风险等级 + 说明信息卡片
前端指标展示	—	F1 / Precision / Recall / anchor accuracy
app/profiles.py 评估 Profile 系统	额外功能	3 个 Profile：通用 / 政府公告 / 法律文书
app/metrics.py BERTScore 指标	额外功能	基于 BERT 词向量的语义相似度

五、当前进度评估

5.1 里程碑进度看板

里程碑	完成标志	目标日	当前状态	风险等级
M1: 校准达标	Pearson r ≥ 0.8	Day 2	✅ 已完成前置调优	● 低
M2: 指标全部达标	F1 / 锚点 / 偏置 / 稳定性通过	Day 5	⌚ Phase 2 全部完成，Phase 3 进展顺利	● 低
M3: 集成测试通过	全流程无 Bug	Day 6	📦 未开始	● 低
M4: 演示材料完备	PPT + 脚本 + Demo 就绪	Day 9	📦 未开始	● 低
M5: 最终提交	全部材料打包提交	Day 10	📦 未开始	● 低

5.2 总体进度状态

当前状态：正常推进，Phase 2 已全部完成，Phase 3 完成前 3 项。

Day 3 完成了偏置检测（P2-1/2/3）、抗偏置指令（P2-4）、稳定性验证（P2-5）、可复现性令牌（P2-6）以及瑕疵检出指标（P3-1）、锚点定位准确率（P3-2）、一致性校准（P3-3）。剩余 P3-4（数据集扩充）和 P3-5（Prompt 调优迭代）将在后续推进。

六、后续安排

后续工作将继续推进 Phase 3 的剩余任务（评估数据集扩充、Prompt 调优迭代），并进入 Phase 6 端到端集成测试阶段，重点检查从 API 调用到结果渲染的完整链路，补足边界测试和异常测试支撑。

七、总结

今天按照研发计划书 Phase 2 和 Phase 3 的任务分解，完成了偏置检测模块的全部四项功能、稳定性验证和可复现性令牌的实现，以及瑕疵检出指标、锚点定位准确率和一致性校准三项核心指标的开发。系统在"抗偏置能力"和"量化验证能力"两个方面实现了关键提升。全组成员任务完成情况正常，进度与计划保持一致。