

大模型内容安全与质量评估智能体 · 研发日报

日期	2026年7月1日（周二）
课题	内容保真度与治理质量评估智能体（LLM-as-Judge）
阶段	Phase 3 — 数据集扩充与 Prompt 调优 + Phase 6 — 端到端集成测试
日报编号	Day 4 / 10
组长	李首澎
组员	阿思晗、由靖喆

一、组员进度汇报

1.1 组员：阿思晗

今日任务：评估数据集扩充 + 边界/异常测试实现

今日围绕数据集扩充和测试用例编写展开辅助工作。

上午在 `data/eval_dataset.json` 中补充了新的人工标注样本（P3-4），覆盖量化指标篡改、段落大幅删除、纯格式优化三类场景，确保优秀/中等/低质三档分布均衡。下午在 `tests/test_day6_minimal.py` 中补充了边界测试用例（P6-2：空文本、超长文本、特殊字符、中英混合）和异常测试用例（P6-3：API Key 错误、网络超时、JSON 畸形）。

任务	完成状态
P3-4 评估数据集扩充	✅ 已完成
P6-2 边界测试用例编写	✅ 已完成
P6-3 异常测试用例编写	✅ 已完成

计划工时：4h 实际工时：约 3.5h 偏差：提前 0.5h

P) D:\trae project\shixun\docs\研发日报\研发日报_Day3.md

```
1 """System / User Prompt 模板 — 面向治理保真度评估的专用 Prompt 设计"""
2 from __future__ import annotations
3
4 from typing import Any, Optional
5
6 # =====
7 # System Prompt
8 # =====
9 SYSTEM_PROMPT = """你是一个专业的内容保真度与治理质量评估智能体（LLM-as-Judge）。
10 你的任务是：比对治理前后的文本，评估治理质量。
11
12 你必须严格按以下四个维度打分，并输出 JSON 格式结果：
13
14 1. **语义一致性 (semantic)** (权重 0.35)：治理后是否保留了原意？核心信息是否完整？是否被扭曲或过度泛化？
15 2. **事实准确性 (factual)** (权重 0.35)：数字、日期、金额、人名、机构名等关键事实是否被篡改？技术参数是否准确？
16 3. **信息结构保真度 (structure)** (权重 0.15)：信息之间的逻辑关系（因果/并列/递进）是否保持？层级结构是否清晰？
17 4. **可读性 (readability)** (权重 0.15)：句子是否通顺？排版是否规范？标点符号是否正确？
18
19 **【评分标准】**
20 - 每个维度独立打分 0.0~1.0，不要因为某个维度差就影响其他维度的评分。
21 - 你的任务是如实反映每个维度的状况，最终总分由系统自动计算。
22 - 不需要输出 overall_score，系统会根据四个维度加权计算。
23
24 **【事实准确性重点关注】**
25 - 数值变化（如 125.8→128.5）即使幅度小，只要涉及核心数据，factual 应给低分
26 - 日期变化（如 8月1日→9月1日）属于关键事实错误
27 - 机构名缩写丢失法定全称（如"国家电网有限公司"→"国网公司"）属于事实不准确
28 - 技术参数变化（如 ±1100千伏→±1000千伏）属于核心事实错误
29
30 **【瑕疵严重程度判定标准】**
31 - **critical**：数量级变化（120万→12万）、核心数据完全篡改、关键日期/法律条款被改、大量内容被删除（>30%）
32 - **major**：数值有明显偏差（如 18.6%→16.8%，差 1.8 个百分点）、重要信息丢失但非关键
33 - **minor**：数值微小偏差（如 3268→3269，差 1 人）、表述微调、标点/空格变化
34 - **不要因为"数字被改了"就一律标 critical**，要看改动幅度和影响
35
36 **【信息结构保真度重点关注】**
```

```
python_version > tests > test_day6_minimal.py > ...
20 def _make_request(request_id: str = "req-1", with_human_label: bool = True) -> EvalRequest:
31     return EvalRequest(**payload)
32
33
34 class Day6MinimalTests(unittest.TestCase):
35     def test_health_endpoint_returns_ok(self) -> None:
36         response: Any = client.get(url="/api/v1/health")
37
38         self.assertEqual(first=response.status_code, second=200)
39         self.assertEqual(first=response.json(), second={"status": "ok", "service": "llm-quality-judge"})
40
41     def test_reproduce_endpoint_returns_not_found_payload_for_unknown_token(self) -> None:
42         response: Any = client.get(url="/api/v1/reproduce/not-exists-token")
43
44         self.assertEqual(first=response.status_code, second=200)
45         body: Any = response.json()
46         self.assertFalse(expr=body["found"])
47         self.assertEqual(first=body["token"], second="not-exists-token")
48         self.assertIn(member="未找到对应历史记录", container=body["message"])
49
50     def test_history_endpoint_returns_basic_structure(self) -> None:
51         response: Any = client.get(url="/api/v1/history")
52
53         self.assertEqual(first=response.status_code, second=200)
54         body: Any = response.json()
55         self.assertEqual(first=set[Any](body.keys()), second={"total_in_db", "returned", "offset", "records"})
56         self.assertIsInstance(obj=body["records"], cls=list)
57         self.assertIsInstance(obj=body["returned"], cls=int)
58         self.assertIsInstance(obj=body["offset"], cls=int)
59
60     def test_batch_evaluate_endpoint_rejects_more_than_50_requests(self) -> None:
61         requests: list[dict[str, Any]] = [
62             _make_request(request_id=f"req-{i}", with_human_label=False).model_dump(mode="json")
63             for i in range(51)
64         ]
```


1.2 组员：由靖喆

今日任务：测试报告整理 + 前端测试结果对接

今日整理了端到端测试、边界测试和异常测试的结果，汇总为阶段验收支撑材料。同时在前端增加了测试结果的展示页面。

任务	完成状态
测试报告整理	✅ 已完成
前端测试结果展示	✅ 已完成

计划工时：2h 实际工时：约 2h 偏差：持平



二、组长汇总

2.1 今日整体进度说明

根据研发计划书安排，Day 4 的核心任务是完成 **端到端集成测试 + 边界/异常 case**（Phase 6 前 3 项），同时收尾 Phase 3 剩余任务。今日完成了 P3-4（数据集扩充）、P3-5（Prompt 调优迭代）、P6-1（端到端集成测试）、P6-2（边界测试）和 P6-3（异常测试）共 5 项任务。Phase 3 全部完成，Phase 6 测试前 3 项完成。

2.2 组员任务完成情况汇总

姓名	今日任务	完成状态	备注
李首澎（组长）	P3-5 Prompt 调优 + P6-1 端到端集成测试 + 验收统筹	✅ 全部完成	核心技术工作
阿思晗	P3-4 数据集扩充 + P6-2/3 测试用例编写	✅ 全部完成	辅助开发
由靖喆	测试报告整理 + 前端对接	✅ 全部完成	按时完成

2.3 组长今日工作内容

今日承担了 Phase 3 收尾和 Phase 6 测试的核心技术工作：

- P3-5 Prompt 调优迭代**：基于前三天校准测试中的高偏差样本，对 `app/prompts.py` 中的 System Prompt 进行了 2-3 轮定向调优——数值敏感性强化（数量级变化标 critical）、格式优化豁免（纯标点调整不扣分）、过度清洗权重提升（删除超 30% 判 critical）。每轮调优后重新校准验证。
- P6-1 端到端集成测试**：对 `main.py` → `app/routes.py` → `app/engine.py` → JSON 解析 → 结果渲染的完整链路进行串联验证，确认各模块数据流一致。
- 验收统筹**：对 Day 1-4 成果归拢，确认 M2/M3 前置条件齐备。

计划工时：6h 实际工时：约 6h 偏差：持平

```
python_version > ... run_calibration.py ...
9   import numpy as np
10  from scipy.stats import pearsonr, spearmanr
11  from dotenv import load_dotenv
12
13  PROJECT_ROOT: Path = Path(__file__).resolve().parent
14  sys.path.insert(0, str(PROJECT_ROOT))
15  load_dotenv()
16
17  from app.engine import evaluate
18  from app.models import EvalRequest
19  from app.calibration import calibrate
20  from app.metrics import compute_flaw_metrics, compute_anchor_accuracy
21
22  # — 加载数据集 —————
23  data_path: Path = PROJECT_ROOT / "data" / "eval_dataset.json"
24  with open(file=data_path, mode="r", encoding="utf-8") as f:
25      samples = json.load(fp=f)
26
27  print("=" * 70)
28  print(f"  校准测试 - 共 {len(samples)} 条样本 (统一调用 engine.py) ")
29  print("=" * 70)
30
31  # — 构建请求 —————
32  requests: list[EvalRequest] = []
33  for s in samples:
34      requests.append(EvalRequest(
35          request_id=s["id"],
36          before_text=s["before_text"],
37          after_text=s["after_text"],
38          human_label={
39              "overall_score": s["human_score"],
40              "label": s.get("label", ""),
41              "flaws": s.get("flaws_gt", []),
42          },
43      ))
```

三、今日研发过程记录

3.1 P3-4 评估数据集扩充

在 `data/eval_dataset.json` 中补充了新的人工标注样本，扩充后数据集覆盖以下场景：

场景类型	样本数	典型特征
优秀治理 (≥0.8)	~40%	仅格式优化，内容保真度高
中等质量 (0.5-0.8)	~35%	轻微信息丢失或表述偏差
低质量 (<0.5)	~25%	数值篡改、大段删除、严重误改

每条样本包含完整的 `human_label` 字段：

```
{
  "human_label": {
    "overall_score": 0.45,
    "flaws": [
      {
        "type": "mis_edit",
```

```
        "severity": "critical",
        "description": "营业收入数值被错误修改：120万元→12万元",
        "location": { "segment_id": "before_1", "char_offset": 12 }
    }
  ]
}
```

3.2 P3-5 Prompt 调优迭代

进行了 2-3 轮调优迭代，每轮流程为：分析高偏差样本 → 定向修改 Prompt → 重新校准 → 对比改善效果。

第一轮：针对数值敏感性不足（120万→12万未被识别为 critical），在 `mis_edit` 说明中增加量化约束。调优后 Pearson r 从 0.61 提升至约 0.72。

第二轮：针对格式优化误罚（纯标点调整被扣语义分），增加格式豁免条款。调优后高偏差样本从 3 条减少至 1 条，Pearson r 提升至约 0.78。

第三轮：针对过度清洗识别不足（删除 40% 内容未被判定为 critical），增加量化阈值。调优后 Pearson r 达到 0.8 以上，里程碑 M1 达标。

3.3 P6-1 端到端集成测试

测试链路：`main.py`（FastAPI 服务入口）→ `app/routes.py`（路由层，6 个端点）→ `app/engine.py`（LLM 调用 + JSON 解析）→ `app/reporter.py`（综合报告生成）→ `static/index.html`（前端渲染）。

验证结果：各模块之间数据流一致，评估请求能够正确从 API 入口传递到 LLM、解析为结构化结果、生成综合报告并渲染到前端页面。

3.4 P6-2 边界测试

测试场景	预期行为	实际结果
空文本输入	返回壳结构，不报错	✅ 通过
超长文本（>5000 字）	正常评估，不超时	✅ 通过
特殊字符（HTML/emoji）	正常处理，不转义异常	✅ 通过
中英混合文本	锚点标记和评估正确	✅ 通过

3.5 P6-3 异常测试

测试场景	预期行为	实际结果
API Key 错误	返回友好错误提示	✅ 通过
网络超时	重试后返回超时提示	✅ 通过
JSON 畸形（LLM 输出非标准 JSON）	三层兜底解析成功	✅ 通过

四、关键产出

产出内容	对应计划任务	说明
data/eval_dataset.json 扩充	P3-4	新增人工标注样本，覆盖三类场景
app/prompts.py 调优	P3-5	2-3 轮迭代，Pearson r ≥ 0.8
端到端集成测试通过	P6-1	API → LLM → 解析 → 渲染全链路
tests/test_day6_minimal.py 边界测试	P6-2	空文本 / 超长 / 特殊字符 / 中英混合
异常测试用例	P6-3	API Key 错误 / 超时 / JSON 畸形
测试报告	P6-1/2/3	阶段验收支撑材料

五、当前进度评估

5.1 里程碑进度看板

里程碑	完成标志	目标日	当前状态	风险等级
M1: 校准达标	Pearson r ≥ 0.8	Day 2	✅ Prompt 调优后达标	● 低
M2: 指标全部达标	F1 / 锚点 / 偏置 / 稳定性 通过	Day 5	✅ Phase 2 + Phase 3 全部完成	● 低
M3: 集成测试通过	全流程无 Bug	Day 6	🕒 P6-1/2/3 已完成	● 低
M4: 演示材料完备	PPT + 脚本 + Demo 就绪	Day 9	🟪 未开始	● 低
M5: 最终提交	全部材料打包提交	Day 10	🟪 未开始	● 低

5.2 总体进度状态

当前状态：进度超前，Phase 2/3 已全部完成，Phase 6 测试已完成前 3 项。

Day 4 完成了 Phase 3 收尾（数据集扩充 + Prompt 调优）和 Phase 6 的端到端集成测试、边界测试、异常测试。M1（校准达标）和 M2（指标全部达标）已确认达成，M3（集成测试通过）的前置条件已齐备。

六、后续安排

后续工作将转入 Phase 4（报告生成与批量评估），重点完成综合评估报告生成器的 7 大模块集成、JSON 报告导出、控制台摘要输出和批量评估脚本。

七、总结

今天按照研发计划书完成了 Phase 3 的收尾工作（P3-4 数据集扩充、P3-5 Prompt 调优迭代）和 Phase 6 的三项测试任务（P6-1 端到端集成、P6-2 边界测试、P6-3 异常测试）。系统当前已具备完整的评估指标体系和基础测试支撑，进度与计划保持一致，为后续报告生成和批量评估做好了准备。