

大模型内容安全与质量评估智能体 · 研发日报

日期	2026年7月2日（周三）
课题	内容保真度与治理质量评估智能体（LLM-as-Judge）
阶段	Phase 4 — 报告生成与批量评估
日报编号	Day 5 / 10
组长	李首澎
组员	阿思晗、由靖喆

一、组员进度汇报

1.1 组员：阿思晗

今日任务：金标准数据集构建 + JSONL 历史持久化

今日围绕数据层建设展开辅助工作。

上午构建了 **金标准数据集 v1.0** (`data/gold_dataset_v1.json`)：从实际治理场景中收集 54 条人工标注样本，经文本相似度去重后保留 34 条，覆盖"Good Governance"和"Over Cleaning"等类别。每条样本包含 4 维度金标准分数、加权总分、verdict、锚点标注和标注元数据。

下午在 `app/storage.py` 中实现了 JSONL 历史持久化，支持按 `request_id` 或 `reproducibility_token` 查询、分页获取和汇总统计。

任务	完成状态
金标准数据集 v1.0（34 条）	✅ 已完成
JSONL 历史持久化（ <code>app/storage.py</code> ）	✅ 已完成

计划工时：3h 实际工时：约 3h 偏差：持平

1.2 组员：由靖喆

今日任务：综合报告前端展示 + 批量评估交互

今日围绕报告链路联调和批量评估验证展开工作。上午在 `static/index.html` 和 `app.py` 中增加了综合报告的结构化展示（Metric 卡片 + DataFrame 着色 + Pass-Fail 徽章），以及批量评估的触发按钮和进度显示。下午对报告生成链路进行了联调验证，确认 `run_full_evaluation()` 的 7 个模块输出能够正确传递到前端展示层。同时对 `run_calibration.py` 校准脚本进行了验证，确认校准流程能够正确调用 `app/calibration.py` 的五项指标计算逻辑，并将结果输出到控制台和报告文件。

任务	完成状态
综合报告前端展示页面	✅ 已完成
批量评估前端交互 + 进度显示	✅ 已完成
报告链路联调验证	✅ 已完成
校准脚本验证	✅ 已完成

计划工时：2h 实际工时：约 2.5h 偏差：超时 0.5h（联调耗时较多）

二、组长汇总

2.1 今日整体进度说明

根据研发计划书安排，Day 5 对应 **Phase 4（报告生成与批量评估）全部 5 项任务**。今日完成了 P4-1 至 P4-5，Phase 4 全部完成。

2.2 组员任务完成情况汇总

姓名	今日任务	完成状态	备注
李首澎（组长）	P4-1 报告生成器 + P4-2 JSON 导出 + P4-3 控制台摘要 + P4-4 验收判定 + P4-5 批量评估	✅ 全部完成	核心技术工作
阿思晗	金标准数据集构建 + JSONL 持久化	✅ 全部完成	数据层建设
由靖喆	前端展示 + 批量评估交互 + 报告链路联调 + 校准脚本验证	✅ 全部完成	前后端联调

2.3 组长今日工作内容

今日承担了 Phase 4 全部 5 项任务的核心开发：

- P4-1 综合评估报告生成器**：在 `app/reporter.py` 中设计并实现了 7 大模块集成架构（评估/校准/稳定性/瑕疵/锚点/偏置/可复现），入口函数 `run_full_evaluation()` 采用异常隔离设计。
- P4-2 JSON 报告导出**：实现了 `export_report_json()` 函数。
- P4-3 控制台摘要输出**：实现了 `print_report_summary()` 函数，输出各维度评分、校准指标和 Pass/Fail 标识。
- P4-4 验收标准自动判定**：实现了 `_generate_checklist()` 函数，对照 I1-I8 验收标准逐项检查（与人工一致性/评分稳定性/瑕疵检出/可解释性/瑕疵可定位/可复现/抗偏置）。
- P4-5 批量评估脚本**：在 `app/batch.py` 中实现了 `batch_evaluate()` 函数，支持并发控制（`asyncio.Semaphore`，默认 5）、指数退避重试（1s/2s/4s，最多 3 次）和 256 条内存缓存。
- 架构设计**：设计了报告生成器的 7 模块集成方案和批量评估的并发/重试/缓存机制。

计划工时：6h 实际工时：约 6h 偏差：持平

```
24 def run_full_evaluation(  
28     run_stability: bool = False,  
29 ) -> dict[str, Any]:  
30     """  
31     运行完整评估流程，输出符合课题12验收标准的综合报告。  
32  
33     包含：  
34     1. 逐条评估（维度评分 + 瑕疵清单 + 可复现令牌）  
35     2. 一致性校准（Pearson/Spearman/MAE/RMSE/一致率）  
36     3. 稳定性分析（多次采样方差）  
37     4. 瑕疵检出指标（Precision/Recall/F1）  
38     5. 锚点定位准确率  
39     6. 偏置分析（长度偏置、位置偏置）  
40     7. 可复现性验证  
41  
42     Args:  
43         requests: 评估请求列表  
44         stability_samples: 稳定性采样次数  
45         char_tolerance: 锚点容差  
46  
47     Returns:  
48         dict: 综合评估报告  
49     """  
50     report: dict[str, Any] = {  
51         "report_meta": {  
52             "generated_at": time.strftime("%Y-%m-%d %H:%M:%S"),  
53             "total_samples": len(requests),  
54             "stability_samples": stability_samples if run_stability else 0,  
55             "char_tolerance": char_tolerance,  
56             "run_stability": run_stability,  
57         },  
58         "per_sample_results": [],  
59         "calibration": {},  
60         "stability_summary": {},  
61         "flaw_metrics": {}.
```

```
3
4
5  async def _evaluate_one(
6      request: EvalRequest,
7      semaphore: asyncio.Semaphore,
8      use_cache: bool,
9      persist: bool,
10  ) -> dict[str, Any]:
11      """单条异步评估（在线程池中运行同步 LLM 调用）"""
12      # 缓存命中
13      if use_cache:
14          cached: EvalResponse | None = _get_cached(request)
15          if cached is not None:
16              return {
17                  "request_id": request.request_id,
18                  "status": "ok",
19                  "from_cache": True,
20                  "result": cached.model_dump(),
21              }
22
23      async with semaphore:
24          loop: AbstractEventLoop = asyncio.get_event_loop()
25          try:
26              resp: EvalResponse = await loop.run_in_executor(
27                  executor=None, func=_evaluate_with_retry, request
28              )
29              if use_cache:
30                  _set_cached(request, resp)
31              if persist:
32                  try:
33                      save_evaluation(response=resp)
34                  except Exception:
35                      pass # 持久化失败不影响主流程
36              return {
37                  "request_id": request.request_id,
```

```

✓ def update_human_verdict(request_id: str, human_verdict: str) -> bool:
    """人工覆写 verdict (pass / fail) 。

    Args:
        request_id: 要覆写的记录 ID
        human_verdict: 人工判定结果 ("pass" 或 "fail")

    Returns:
        是否找到并更新成功
    """
    if not HISTORY_PATH.exists():
        return False

    lines: list[str] = HISTORY_PATH.read_text(encoding="utf-8").splitlines()
    updated = False
    new_lines: list[str] = []

    for line in lines:
        if not line.strip():
            continue
        try:
            rec = json.loads(s=line)
            if rec.get("request_id") == request_id:
                rec["human_verdict"] = human_verdict
                updated = True
            new_lines.append(json.dumps(obj=rec, ensure_ascii=False))
        except json.JSONDecodeError:

```

三、今日研发过程记录

3.1 P4-1 综合评估报告生成器

报告生成器将 7 个独立模块聚合为统一报告结构，采用异常隔离设计：

```

def run_full_evaluation(request: EvalRequest) -> dict:
    # 1. 评估 → engine.evaluate()
    # 2. 校准 → calibration.calibrate()
    # 3. 稳定性 → stability.run_stability()
    # 4. 瑕疵 → metrics.compute_flaw_metrics()
    # 5. 锚点 → metrics.compute_anchor_accuracy()
    # 6. 偏置 → debias 模块
    # 7. 可复现 → reproducibility_token
    # 8. 验收 → _generate_checklist() (I1-I8 验收标准)

```

3.2 金标准数据集 v1.0

数据集构建流程：收集实际治理文本对 → 人工标注 4 维度分数 + verdict + 锚点 → 交叉审核 → 文本相似度去重（54→34 条）。样本覆盖"Good Governance"（治理质量高）和"Over Cleaning"（过度清洗）等类别，每条样

本包含完整的标注元数据。

3.3 批量评估增强

- **并发控制**: `asyncio.Semaphore(5)` 限制同时 API 请求数;
- **指数退避重试**: `1s → 2s → 4s`, 最多 3 次;
- **内存缓存**: 256 条内存缓存, 相同输入直接返回;
- **进度回调**: 每条评估完成后调用 `callback` 报告进度。

四、关键产出

产出内容	对应任务	说明
<code>app/reporter.py</code> 综合报告	P4-1	7 大模块集成
<code>output/eval_report.json</code>	P4-2	JSON 报告导出
控制台彩色摘要	P4-3	ANSI 格式化
验收标准自动判定	P4-4	I1-I8 验收标准逐项检查
<code>app/batch.py</code> 批量评估	P4-5	遍历 <code>eval_dataset.json</code>
<code>data/gold_dataset_v1.json</code>	额外	34 条金标准样本
批量评估增强	额外	并发/重试/内存缓存/进度回调
<code>app/storage.py</code> 历史持久化	额外	JSONL 分页查询

五、当前进度评估

5.1 里程碑进度看板

里程碑	完成标志	目标日	当前状态	风险等级
M1: 校准达标	Pearson $r \geq 0.8$	Day 2	✅ 已达标	🟢 低
M2: 指标全部达标	F1 / 锚点 / 偏置 / 稳定性 通过	Day 5	✅ 验收自动判定已实现	🟢 低
M3: 集成测试通过	全流程无 Bug	Day 6	✅ 端到端测试已通过	🟢 低
M4: 演示材料完备	PPT + 脚本 + Demo 就绪	Day 9	🟡 未开始	🟢 低
M5: 最终提交	全部材料打包提交	Day 10	🟡 未开始	🟢 低

5.2 总体进度状态

当前状态：进度超前，Phase 1-4 全部完成，Phase 6 测试已完成前 3 项。

Day 5 完成了 Phase 4 全部任务和金标准数据集构建。系统当前能够一键生成完整评估报告，批量评估已跑通。后续将进入 Phase 5（UI 精修）和架构优化阶段。

六、后续安排

后续工作将转入 Phase 5（Web 应用与可视化），重点完成 FastAPI 后端端点完善、Streamlit 演示版精修、结果可视化增强和自定义 CSS 美化。同时将推进评估引擎架构优化和多模型适配基础建设。

七、总结

今天按照研发计划书 Phase 4 全部任务完成了综合评估报告生成器和批量评估脚本的开发，同时构建了金标准数据集 v1.0、增强了批量评估并发控制和重试机制、实现了 JSONL 历史持久化。系统已具备一键生成完整评估报告的能力，为后续 UI 精修和最终验收打下了坚实基础。