

大模型内容安全与质量评估智能体 · 研发日报

日期	2026年7月3日（周四）
课题	内容保真度与治理质量评估智能体（LLM-as-Judge）
阶段	Phase 5 — Web 应用与可视化 + 架构优化与多模型适配
日报编号	Day 6 / 10
组长	李首澎
组员	阿思晗、由靖喆

一、组员进度汇报

1.1 组员：阿思晗

今日任务：DSPy 集成 + 结果可视化 + 离线校准 Agent

今日围绕 DSPy 框架集成和辅助功能展开工作。

上午在 `app/dspy_eval.py` 中完成了 DSPy 集成：实现了 `TextEvalSignature` 和 `StrictEvalSignature`（评估签名）、`TextEvaluator` / `StrictEvaluator` 模块（使用 `ChainOfThought`）、输出断言和 `BootstrapFewShot` Teleprompter 优化器。

下午在 `app.py` 中实现了结果可视化（P5-4）：Metric 卡片展示 `overall_score` 和各维度评分、DataFrame 瑕疵表按 `severity` 着色、Pass-Fail 徽章。随后在 `app/calibration_agent.py` 中实现了离线校准 Agent——加载金标准数据集、运行模型评估、计算一致性指标、训练校准器、检测异常并生成格式化报告。

任务	完成状态
DSPy 集成（Signature + Module + Teleprompter）	✅ 已完成
P5-4 结果可视化（Metric / DataFrame / 徽章）	✅ 已完成
离线校准 Agent	✅ 已完成

计划工时：4h 实际工时：约 4h 偏差：持平

1.2 组员：由靖喆

今日任务：Phase 5 前端与 CSS + Mimo 2.5 Pro 前端适配

完成了 **P5-2 中文前端页面**（`static/index.html` 布局/字体/配色优化）、**P5-3 Streamlit 演示版**（侧边栏 API Key + 双文本域 + 实时评估）、**P5-5 加载动画**（`st.spinner` + `st.error` 友好异常提示）、**P5-6 自定义 CSS**（渐变标题、圆角卡片、按钮 hover 动效）。随后完成了 Mimo 2.5 Pro 前端适配，在 Streamlit 侧边栏增加 Mimo 2.5 Pro API Key 输入，并实现了多模型切换的前端交互逻辑——用户可在侧边栏选择 DeepSeek 或 Mimo

2.5 Pro，前端自动携带模型标识发送评估请求。最后对 FastAPI 后端与前端之间的端到端链路进行了联调，确认评估、批量评估、历史查询等接口在前端均可正常调用。

任务	完成状态
P5-2 中文前端页面优化	✅ 已完成
P5-3 Streamlit 演示版完善	✅ 已完成
P5-5 加载动画 + 异常友好提示	✅ 已完成
P5-6 自定义 CSS（渐变 / 圆角 / hover）	✅ 已完成
Mimo 2.5 Pro 前端适配 + 多模型切换交互	✅ 已完成
FastAPI 端到端链路联调	✅ 已完成

计划工时：2h 实际工时：约 3h 偏差：超时 1h（多模型切换和联调耗时较多）

二、组长汇总

2.1 今日整体进度说明

根据研发计划书安排，Day 6 对应 **Phase 5（Web 应用与可视化）全部 6 项任务**。今日完成了 P5-1 至 P5-6，Phase 5 全部完成。同时利用进度超前的时间窗口，完成了评估引擎架构优化（模块化函数调用链 + 三层 JSON 解析 + Pydantic 验证 + JSON mode）、对齐预处理模块、软惩罚机制替代硬 veto、DSPy 集成（含 ChainOfThought 和 BootstrapFewShot Teleprompter）、统一评估协议、模型注册表、三模型适配器（DeepSeek/Mimo 2.5 Pro/GPT）、MultiModelCalibrator、离线校准 Agent 和 LLM 缓存/速率限制/流式输出等基础设施。

系统当前已具备完整的 Web 前后端、多模型适配能力和架构级优化，进度超前约 2 天。

2.2 组员任务完成情况汇总

姓名	今日任务	完成状态	备注
李首澎 (组长)	P5-1 FastAPI 后端 + 评估引擎架构优化 + 对齐模块 + 软惩罚 + 协议层 + 注册表 + 3 适配器 + 校准器 + 缓存/限流/流式	✅ 全部完成	核心架构工作
阿思晗	DSPy 集成 + P5-4 可视化 + 离线校准 Agent	✅ 全部完成	辅助模块开发
由靖喆	P5-2/3/5/6 前端/CSS/动画 + Mimo 2.5 Pro 前端适配 + 多模型前端切换 + 端到端联调	✅ 全部完成	前端 + 联调

2.3 组长今日工作内容

今日承担了 Phase 5 后端和架构重构的核心开发工作：

1. **P5-1 FastAPI 后端**：在 `app/routes.py` 中补全 6 个 API 端点，配置 CORS 和静态文件挂载。

- 2. 评估引擎架构优化：将 `app/chain.py` 重构为模块化函数调用链（`build_prompt` → `llm.invoke` → `parse_llm_output` → `validate` → `post_process`），引入三层 JSON 解析兜底（直接解析 → Markdown 代码块提取 → 大括号定位）+ Pydantic 验证 + JSON mode。
- 3. 对齐预处理模块：实现了 `build_anchored_text()` 函数，按段落配对治理前后文本并标记 `[Before N]` / `[After N]`，为 LLM 提供结构化的对比锚点。
- 4. 软惩罚机制：将原有的一票否决（veto）硬 cap 替换为风险聚合（Risk Aggregation）——取所有瑕疵中最重的惩罚因子，不连续相乘，避免多个瑕疵导致分数归零。
- 5. 统一评估协议：在 `app/protocol.py` 中定义 `EvaluationProtocol` 抽象基类。
- 6. 模型注册表：在 `app/model_registry.py` 中实现 `ModelRegistry` 单例。
- 7. 模型适配器：在 `app/adapters.py` 中实现 DeepSeek/Mimo 2.5 Pro/GPT 三个适配器。
- 8. 评分校准器：在 `app/calibrator.py` 中实现 `ScoreCalibrator` + `MultiModelCalibrator`。
- 9. 基础设施：LLM 缓存（`InMemoryCache` + `SQLiteCache`）、速率限制、流式输出、Callback 追踪。

计划工时：6h 实际工时：约 6.5h 偏差：超时 0.5h

三、今日研发过程记录

3.1 Phase 5 交付物

计划任务	交付物	说明
P5-1 FastAPI 后端	<code>app/routes.py</code>	6 个端点： evaluate/batch/calibrate/stability/history/health
P5-2 中文前端	<code>static/index.html</code>	布局/字体/配色优化
P5-3 Streamlit 演示版	<code>app.py</code>	侧边栏 Key + 双文本域 + 实时评估
P5-4 结果可视化	<code>app.py</code>	Metric 卡片 + DataFrame 着色 + Pass-Fail 徽章
P5-5 加载动画	<code>app.py</code>	<code>st.spinner</code> + <code>st.error</code> 友好提示
P5-6 自定义 CSS	<code>app.py</code>	渐变标题 / 圆角卡片 / hover 动效

3.2 评估引擎架构优化

重构后评估链路：`build_prompt_messages` → `llm.invoke` → `parse_llm_output` → `validate_llm_output` → `apply_soft_penalty`。采用模块化函数调用链，每个环节独立可测。引入三层 JSON 解析兜底（直接解析 → Markdown 代码块提取 → 大括号定位），配合 JSON mode（`response_format: {"type": "json_object"}`）和 Pydantic 验证，确保 LLM 输出的结构化和合法性。后处理采用软惩罚（风险聚合）替代原有的一票否决机制。

3.3 多模型适配体系



- └─ ScoreCalibrator / MultiModelCalibrator (校准层)
- └─ CalibrationAgent (离线校准辅助)

四、关键产出

产出内容	对应任务	说明
app/routes.py 6 端点	P5-1	评估/批量/校准/稳定性/历史/健康
static/index.html	P5-2	中文前端优化
app.py Streamlit	P5-3/P5-4/P5-5/P5-6	演示版 + 可视化 + 动画 + CSS
app/chain.py 评估引擎	架构优化	模块化函数链 + 三层 JSON 解析 + Pydantic 验证 + JSON mode + 缓存 + 限流
app/dspy_eval.py DSPy	架构优化	ChainOfThought + BootstrapFewShot Teleprompter
app/protocol.py 协议层	多模型适配	EvaluationProtocol 抽象基类
app/model_registry.py 注册表	多模型适配	单例注册 + evaluate_all
app/adapters.py 三适配器	多模型适配	DeepSeek + Mimo 2.5 Pro + GPT
app/calibrator.py 校准器	多模型适配	MultiModelCalibrator + auto_calibrate
app/calibration_agent.py	多模型适配	离线校准 Agent
EvalCallbackHandler	基础设施	Token/延迟追踪
SSE 流式输出	基础设施	实时结果推送

五、当前进度评估

5.1 里程碑进度看板

里程碑	完成标志	目标日	当前状态	风险等级
M1: 校准达标	Pearson $r \geq 0.8$	Day 2	✅ 已达标	🟢 低
M2: 指标全部达标	F1 / 锚点 / 偏置 / 稳定性 通过	Day 5	✅ 已达标	🟢 低
M3: 集成测试通过	全流程无 Bug	Day 6	✅ 已通过	🟢 低
M4: 演示材料完备	PPT + 脚本 + Demo 就绪	Day 9	🟪 未开始	🟢 低
M5: 最终提交	全部材料打包提交	Day 10	🟪 未开始	🟢 低

5.2 总体进度状态

当前状态：进度超前 2 天，Phase 1-5 全部完成，多模型适配和架构优化已到位。

截至 Day 6，项目已完成 Phase 1-5 全部计划任务，并提前完成了架构优化（模块化评估引擎/DSPy）和多模型适配（3 个适配器 + 校准器 + Agent）。后续将专注于答辩材料准备和最终验收。

六、后续安排

后续工作将转入答辩材料准备阶段，重点完成答辩 PPT（项目背景 / 架构 / 核心技术 / 指标数据 / Demo 截图）、演示脚本（3 组典型用例）和最终验收材料打包。

七、总结

今天按照研发计划书 Phase 5 全部任务完成了 Web 应用与可视化工作，同时完成了评估引擎架构优化（模块化函数链 + 对齐预处理 + 软惩罚）、DSPy 集成（含 Teleprompter 自动优化）、多模型适配体系（协议/注册表/3 个适配器/校准器/Agent）和缓存/限流/流式等基础设施。系统已具备最终演示和验收的技术基础。