

大模型内容安全与质量评估智能体 · 研发日报

日期	2026年7月6日（周一）
课题	内容保真度与治理质量评估智能体（LLM-as-Judge）
阶段	Phase 6 — 核心模块补全 + 多模型验证 + 7/4-7/5 工作合并
日报编号	Day 7 / 10
组长	李首澎
组员	阿思晗、由靖喆

说明：7/4（周六）和 7/5（周日）为非提交日，其工作内容合并至本日报告中。

一、组员进度汇报

1.1 组员：阿思晗

今日任务：DSPy Teleprompter 验证 + 多模型对比测试 + 指标数据整理

7/4 工作 — DSPy Teleprompter 验证

对 `app/dspy_eval.py` 中的 `BootstrapFewShot` Teleprompter 优化器进行了验证，确认其能够在金标准数据集上自动优化 Prompt 的 few-shot 示例选择，提升评估质量。同时整理了系统架构图和核心流程图，展示从用户输入到 LLM 评估到结果可视化的完整链路。

7/5 工作 — 多模型对比 + 指标数据整理

使用 `app/model_registry.py` 的 `evaluate_all()` 功能，对 DeepSeek、Mimo 2.5 Pro 和 GPT 三个模型在相同输入上进行了对比测试，记录各模型的评分差异和一致性。同时整理了各项验收指标的最新数据。

今日整合

将多模型对比结果和指标数据汇总，确认 DSPy 自动优化能力的有效性。

任务	完成状态
DSPy Teleprompter 自动优化验证	✅ 已完成
多模型对比测试（DeepSeek / Mimo 2.5 Pro / GPT）	✅ 已完成
验收指标数据整理（I1-I8）	✅ 已完成

计划工时：4h 实际工时：约 5h（含 7/4+7/5） 偏差：超时 1h

1.2 组员：由靖喆

今日任务：指标数据整理 + 多模型测试数据 + 前端优化

7/4 工作 — 前端优化 + 截图采集

对系统前端进行优化，采集了系统 Demo 截图，包括评估界面、综合报告页面、批量评估进度等。

7/5 工作 — 指标数据整理

整理了各项验收指标的最新数据：Pearson $r \geq 0.8$ (M1 已达标)、方差 < 0.005 (稳定性已验证)、瑕疵 $F1 \geq 0.8$ (已实现)、锚点准确率 $\geq 90\%$ (已实现)，汇总为指标数据表格。

今日整合 — 多模型测试数据整理

对多模型对比测试的数据进行整理和分析。

任务	完成状态
验收指标数据表制作 (I1-I8 达标情况)	✅ 已完成
多模型对比测试数据整理	✅ 已完成
前端优化 + 截图采集	✅ 已完成

计划工时：3h 实际工时：约 3.5h (含 7/4+7/5) 偏差：超时 0.5h

二、组长汇总

2.1 今日整体进度说明

Day 7 的核心任务是补全核心模块 (Diff 瑕疵检测、评估置信度、风险等级) 和验证多模型适配能力。本日报告合并了 7/4 和 7/5 两天的工作内容。

今日完成了 Diff 瑕疵检测模块、评估置信度计算、风险等级判定三个核心模块的开发，同时完成了 DSPy Teleprompter 自动优化验证和多模型对比测试。

2.2 组员任务完成情况汇总

姓名	今日任务	完成状态	备注
李首澎 (组长)	Diff/Confidence/RiskLevel 模块 + DSPy 验证 + 多模型对比	✅ 全部完成	核心模块开发
阿思晗	DSPy 验证 + 多模型测试 + 指标数据整理	✅ 全部完成	验证 + 数据
由靖喆	指标数据表 + 多模型数据 + 前端优化	✅ 全部完成	数据 + 前端

```
5  查看问题 (Alt+F8)  快速修复... (Ctrl+.)  ❖ Fix (Ctrl+I)
6  import re
7
8  💡
9  def _char_diff(before: str, after: str) -> list[dict[str, Any]]:
10     """字符级 diff: 找出 before→after 的具体变更。
11
12     返回变更列表, 每项包含:
13     type: substitution / deletion / insertion
14     before_text: 原文片段
15     after_text: 改后片段
16     before_start / before_end: 原文中的位置
17     after_start / after_end: 改后文本中的位置
18     """
19     sm: SequenceMatcher[str] = difflib.SequenceMatcher(None, before, after)
20     changes: list[dict[str, Any]] = []
21
22     for tag, i1, i2, j1, j2 in sm.get_opcodes():
23         if tag == "equal":
24             continue
25         changes.append({
26             "type": tag, # substitution / deletion / insertion
27             "before_text": before[i1:i2] if tag != "insertion" else "",
28             "after_text": after[j1:j2] if tag != "deletion" else "",
29             "before_start": i1,
30             "before_end": i2,
31             "after_start": j1,
32             "after_end": j2,
33         })
34
```

2.3 组长今日工作内容

1. **Diff 瑕疵检测模块**: 在 `app/chain.py` 中实现了 `detect_flaws()` 函数, 对配对段落做字符级 diff, 自动分类为 factual/structure/omission/modification 并判定严重程度。Diff 检测结果注入 Prompt 作为算法预检参考。
2. **评估置信度 (Confidence)**: 实现了 `compute_confidence()` 函数, 基于三个因子计算每次评估的置信度 (0~1): Diff 一致性 (算法检测与 LLM 瑕疵的覆盖率)、理由完整度 (维度 reason 详细程度)、规则一致性 (Diff 严重程度与 LLM 维度分数是否冲突)。
3. **风险等级 (risk_level)**: 实现了 `compute_risk_level()` 函数, 结合分数和置信度输出 high/medium/low 风险等级, 指导人工审核优先级。
4. **DSPy Teleprompter 验证**: 在金标准数据集上验证 BootstrapFewShot 优化器的自动优化效果。
5. **多模型对比测试**: 使用 `evaluate_all()` 对 DeepSeek/Mimo 2.5 Pro/GPT 三个模型进行对比测试, 分析评分差异。

计划工时: 5h 实际工时: 约 6h (含 7/4+7/5) 偏差: 超时 1h

💡 • 其他 → low

```
def compute_risk_level(overall_score: float, confidence: float) -> str:
    """计算风险等级，指导人工审核优先级。

    结合分数和置信度：
    - score < 0.3 或 (score < 0.5 且 confidence < 0.6) → high
    - score < 0.7 或 confidence < 0.5 → medium
    - 其他 → low
    """
    if overall_score < 0.3:
        return "high"
    if overall_score < 0.5 and confidence < 0.6:
        return "high"
    if overall_score < 0.7 or confidence < 0.5:
        return "medium"
    return "low"
```

```
def _classify_change(change: dict[str, Any]) -> tuple[str, str]:
    """对单个变更进行分类和严重程度判定。
```

分类规则：

category:

- factual: 数字、日期、金额等事实性数据被改动
- structure: 结构被破坏（表格→文本、列表→段落等）
- omission: 内容被删除
- modification: 表述被改写（非事实性）
- addition: 新增内容

severity:

- critical: 关键事实被篡改 / 大量内容被删 / 结构被破坏
- major: 重要信息丢失或改写
- minor: 轻微表述调整

"""

```
before_txt = change.get("before_text", "")
```

```
after_txt = change.get("after_text", "")
```

```
change_type = change["type"]
```

数字/日期/金额模式

```
num_pattern = r"\d+[\.\d]*[%%亿万]?"
```

删除

```
if change_type == "deletion":
```

```
    deleted_len: int = len(before_txt)
```

```
    if deleted_len > 50:
```

```
        return "omission", "critical"
```

```
    elif deleted_len > 15:
```

```
        return "omission", "major"
```

三、今日研发过程记录

3.1 系统架构

四层架构设计：



3.2 多模型对比测试

使用 `evaluate_all()` 在相同输入上对比三个模型：

模型	overall_score	响应延迟	Token 消耗
DeepSeek	0.78	~2.7s	~800
Mimo 2.5 Pro	0.75	~3.1s	~850
GPT	0.82	~2.3s	~750

三个模型评分差异在 +/-0.07 以内，经 MultiModelCalibrator 校准后差异进一步缩小。

3.3 DSPy Teleprompter 验证

`BootstrapFewShot` 优化器在金标准数据集上自动选择了最优的 few-shot 示例组合，优化后的 Prompt 在测试样本上的一致性指标有所提升，验证了 DSPy 自动优化能力的有效性。

3.4 Diff 瑕疵检测模块

`detect_flaws()` 实现了三层检测架构：

- 1. **确定性规则**：表格/列表结构丢失检测
- 2. **段落级相似度**：基于 `difflib.SequenceMatcher` 的段落配对分析
- 3. **字符级 diff**：数值变更、删除、修改的精确定位

检测结果自动注入 Prompt，作为 LLM 的算法预检参考。

四、关键产出

产出内容	对应任务	说明
detect_flaws()	Diff 瑕疵检测	三层检测架构（规则+段落+字符）
compute_confidence()	评估置信度	三因子计算（Diff一致性+理由完整度+规则一致性）
compute_risk_level()	风险等级	high/medium/low 指导人工审核
多模型对比结果	验证	DeepSeek / Mimo 2.5 Pro / GPT 评分对比
DSPy Teleprompter 验证	验证	BootstrapFewShot 优化效果确认

五、当前进度评估

5.1 里程碑进度看板

里程碑	完成标志	目标日	当前状态	风险等级
M1: 校准达标	Pearson r >= 0.8	Day 2	✅ 已达标	低
M2: 指标全部达标	F1 / 锚点 / 偏置 / 稳定性 通过	Day 5	✅ 已达标	低
M3: 集成测试通过	全流程无 Bug	Day 6	✅ 已通过	低
M4: 演示材料完备	脚本 + Demo 就绪	Day 9	准备中	低
M5: 最终提交	全部材料打包提交	Day 10	未开始	低

5.2 总体进度状态

当前状态：进度正常，核心模块已补全，多模型验证已完成。

Day 7 完成了 Diff 瑕疵检测、评估置信度、风险等级三个核心模块的开发，以及 DSPy Teleprompter 验证和多模型对比测试。后续将进行最终指标复核和材料打包。

六、后续安排

后续工作将对全指标进行最终复核，完成验收材料打包。

七、总结

今天（含 7/4+7/5）完成了 Diff 瑕疵检测模块、评估置信度和风险等级三个核心模块的开发，同时完成了 DSPy Teleprompter 自动优化验证和多模型对比测试。全组成员任务完成情况正常，系统核心功能已完备。