

大模型内容安全与质量评估智能体 · 研发日报

日期	2026年7月9日（周四）
课题	内容保真度与治理质量评估智能体（LLM-as-Judge）
阶段	Phase 5 + Phase 6 — 全指标复核 + 性能优化 + Prompt 增强
日报编号	Day 9 / 10
组长	李首澎
组员	阿思晗、由靖喆

一、组员进度汇报

1.1 组员：阿思晗

今日任务：全指标复核 + 金标准校准测试 + 前端交互优化

上午 — 全指标复核

对系统中的全部评估指标进行了最终复核，逐一验证计算逻辑和输出结果的正确性：

指标	模块	验证结果
Pearson r	app/calibration.py	计算正确
Spearman rho	app/calibration.py	计算正确
MAE / RMSE	app/calibration.py	计算正确
Cohen's Kappa	app/metrics.py	计算正确
Kendall's W	app/metrics.py	计算正确
ROUGE-L	app/metrics.py	计算正确
BERTScore	app/metrics.py	计算正确
瑕疵 F1	app/metrics.py	计算正确
锚点准确率	app/metrics.py	计算正确

同时运行了 `run_calibration.py` 对金标准数据集进行全量校准测试，确认各项指标的最新数值均满足验收标准。

下午 — 前端交互优化

对 `static/index.html` 进行了交互优化：增加了输入框的 placeholder 提示、优化了评估按钮的 loading 状态、改善了错误提示的显示样式。同时整理了验收指标汇总表，将 I1-I8 的达标情况、最新数值和目标阈值汇总为一张表格。

任务	完成状态
全指标复核（9 项指标逐一验证）	已完成
金标准数据集全量校准测试	已完成
前端交互优化（placeholder / loading / 错误提示）	已完成
验收指标汇总表整理（I1-I8）	已完成

计划工时：5h 实际工时：约 5h 偏差：持平

1.2 组员：由靖喆

今日任务：UI 细节打磨 + CSS 调整 + 全量测试结果整理

上午 — UI 细节打磨

对 `app.py` 进行了 UI 细节打磨：优化了 Metric 卡片的间距和对齐、调整了 DataFrame 的列宽和行高、改善了 Pass-Fail 徽章的颜色对比度、增加了评分维度的可视化雷达图。

下午 — CSS 调整 + 数据整理

对 `app.py` 的自定义 CSS 进行了细节调整：微调了渐变标题的颜色过渡、优化了圆角卡片的阴影效果、改善了按钮 hover 动效的流畅度。同时对 25 条数据集的全量测试结果进行了整理和分析，标注了偏差超过 0.2 的样本及其偏差原因。

任务	完成状态
UI 细节打磨（Metric / DataFrame / 徽章 / 雷达图）	已完成
CSS 细节调整（渐变 / 阴影 / hover）	已完成
全量测试结果整理	已完成

计划工时：3h 实际工时：约 3h 偏差：持平

二、组长汇总

2.1 今日整体进度说明

Day 9 的核心任务是全指标复核、性能优化和 Prompt 增强。今日完成了全部 9 项指标的最终复核、Prompt 精简与性能优化、约束词删除检测、定义条款变更检测、Profile 实体严格性规则，以及校准脚本的 Bug 修复。I1-I8 全部达标。

2.2 组员任务完成情况汇总

姓名	今日任务	完成状态	备注
李首澎（组长）	全指标复核 + 性能优化 + 约束词/定义条款检测 + Profile 实体严格性 + 校准脚本修复	全部完成	核心验收 + Prompt 优化
阿思哈	全指标复核 + 校准测试 + 前端交互优化 + 验收指标汇总表	全部完成	验证 + 数据
由靖喆	UI 打磨 + CSS 调整 + 全量测试结果整理	全部完成	前端 + 数据

2.3 组长今日工作内容

1. **全指标复核**：逐一验证 9 项指标（Pearson/Spearman/Kappa/Kendall's W/ROUGE-L/BERTScore/F1/锚点/偏置）的计算逻辑和最新数值，确认 I1-I8 全部达标。
2. **性能优化**：分析 EvalCallbackHandler 延迟数据，精简 Prompt（减少约 200 tokens，-17%），调整 max_tokens（2048->1024），响应时间从 3.2s 降至 2.7s（-16%）。
3. **约束词删除检测**：在 Prompt 中新增约束词检测规则——当治理后文本删除了"不得""必须""应当""不少于""不超过""至少""最高""最低""以内""以上"等约束词时，即使"大意保留"，factual <= 0.4、semantic <= 0.5。
4. **定义条款变更检测**：在 Prompt 中新增定义条款检测规则——当治理后文本删除或泛化了"书面""口头""签署前后""明确标注""保密""机密"等定义性限定词时，属于定义条款弱化，factual <= 0.4、semantic <= 0.5。
5. **Profile 实体严格性**：为政务通告模式和法律文书模式增加了实体名称严格性规则——政务模式要求机构名必须使用法定全称、技术参数必须精确；法律模式要求定义条款逐字保留、限定词不得删除。
6. **校准脚本修复**：修复 run_calibration.py 中 human_score 字段名不匹配的问题——数据集使用 human_scores（含四维度分解），脚本改为通过加权公式（semantic x 0.35 + factual x 0.35 + structure x 0.15 + readability x 0.15）计算总分。
7. **验收标准自动判定验证**：确认 reporter.py 中 _generate_checklist() 的 I1-I8 判定逻辑与研发计划书一致。

计划工时：6h 实际工时：约 6h 偏差：持平

三、今日研发过程记录

3.1 全指标复核结果

编号	指标	目标值	最新值	达标
I1	Pearson r	>= 0.8	0.83	达标
I2	方差	< 0.005	0.003	达标
I3	瑕疵 F1	>= 0.8	0.82	达标
I4	锚点准确率	>= 90%	92%	达标
I5	可解释性	reason 字段	已实现	达标
I6	瑕疵可定位	行级锚点	已实现	达标

编号	指标	目标值	最新值	达标
I7	可复现	SHA256 token	已实现	达标
I8	抗偏置	偏置检测	已实现	达标

3.2 性能优化效果

优化项	优化前	优化后	改善
Prompt Token 数	~1200	~1000	-17%
max_tokens	2048	1024	-50%
平均响应时间	~3.2s	~2.7s	-16%

3.3 Prompt 增强

新增了三类检测规则，提升系统对关键事实变更的敏感度：

1. 约束词删除检测：覆盖限定性副词、数量约束、政策阈值、时间约束、范围约束五大类。

2. 定义条款变更检测：覆盖主体限定、方式限定、时间限定、认定标准、保密级别五大类。

3. Profile 实体严格性：政务模式要求法定全称+技术参数精确；法律模式要求定义条款逐字保留。

四、关键产出

产出内容	对应任务	说明
全指标复核报告	验收	9 项指标全部达标
验收指标汇总表 (I1-I8)	验收	达标情况 + 最新数值 + 目标阈值
性能优化	优化	响应时间降低 16%
约束词删除检测	Prompt 增强	五大类约束词覆盖
定义条款变更检测	Prompt 增强	五大类定义条款覆盖
Profile 实体严格性	Prompt 增强	政务/法律模式实体名称规则
校准脚本修复	Bug 修复	human_score 字段名不匹配

五、当前进度评估

5.1 里程碑进度看板

里程碑	完成标志	目标日	当前状态	风险等级
M1-M3	已达标	Day 6	已完成	低
M4: 材料完备	用例 + Demo 就绪	Day 9	已就绪	低
M5: 最终提交	全部材料打包提交	Day 10	明日完成	低

5.2 总体进度状态

当前状态：全指标达标，Prompt 增强完成，性能优化到位，明日可最终提交。

六、后续安排

明日将完成全部材料整理打包和最终提交。

七、总结

今天完成了全指标最终复核（I1-I8 全部达标）、性能优化（响应时间 -16%）、Prompt 增强（约束词检测+定义条款检测+Profile 实体严格性）和校准脚本 Bug 修复。系统核心功能和验收指标均已完备。