

课题12 · 内容保真度与治理质量评估智能体 — 课题汇报

课题	内容保真度与治理质量评估智能体（LLM-as-Judge）
组长	李首澎
组员	阿思晗、由靖喆

一、课题背景与研究动机

1.1 问题是什么

自动化数据治理（去噪、修复、归一化）会对原始文本进行改写，但"改写"本身是有风险的：

- **过度清洗**：删掉了有效信息（如删除完整段落、压缩关键内容）
- **误改语义**：修改了数值、日期、人名等关键事实（如 120万→12万）
- **结构破坏**：打乱了原始文本的排版、表格、层级关系

要让治理结果可信，必须有一种能力来评估"治理前后语义是否一致、是否过度改写、可读性与结构是否合格"。

1.2 为什么用 LLM 做裁判

传统规则方法（如关键词匹配、编辑距离）难以理解语义层面的变化。用大模型做裁判（LLM-as-Judge）是当前评估范式的前沿方向，但其公认的难点在于：

- **评分稳定性**：同一输入多次评估，分数是否一致？
- **人类一致性**：模型评分与人工判断是否吻合？
- **可解释性**：能否给出让人信服的判定理由？
- **抗偏置**：是否会因文本长度、瑕疵位置等因素产生系统性偏差？

1.3 本课题的差异化定位

对比维度	开源通用评测	本课题
场景	一般生成质量打分	治理前后比对（保真度）
研究对象	打分本身	裁判本身的可信度
瑕疵定位	无	锚点级定位（回溯到具体位置）
可复现性	一般不要求	SHA256 令牌，固定策略可复现
抗偏置	一般不涉及	长度/位置偏置检测与缓解

一句话概括： 本课题不是做"打分工具"，而是做"可信赖的裁判"——面向治理前后比对这一特定场景，把裁判的"稳、准、可解释、可复现"作为研究核心。


二、研究目标

设计并实现一个内容保真度与治理质量评估智能体：

抽样比对治理前后文本，判定语义一致性、识别过度清洗与误改、评估可读性与结构质量，输出可锚点定位、可复现的评估结果（维度评分 + 锚点级瑕疵清单 + 判定理由）。作为服务被质检环节按需调用。


三、系统架构

3.1 整体架构图





3.2 评估核心流程



四、核心能力实现

4.1 语义一致性评估

目标：治理前后比对，判定是否保真。

实现方式：

- **Prompt 维度定义：**在 System Prompt 中定义"语义一致性"维度（权重 0.35），要求 LLM 检查核心事实、实体名称、量化指标是否被误改或丢失
- **规则引擎补充：**`detect_flaws()` 通过字符级 diff 检测数值变化（变化幅度 > 10% 自动标记为 critical 级 `mis_edit`）
- **Profile 增强：**政府公告 Profile 对日期/期限/义务敏感，法律文书 Profile 对条款引用/权利义务敏感

评分标准：

分数区间	含义
0.9 – 1.0	完全保真，仅做格式优化
0.7 – 0.9	轻微表述变化，核心事实无损
0.5 – 0.7	存在信息丢失或轻微误改
0.3 – 0.5	关键事实被篡改或大量内容被删
0.0 – 0.3	语义严重偏离，治理基本失败

4.2 过度清洗/误改识别

目标：定位被错误删除或改写的内容。

实现方式：

- **过度清洗（over_clean）检测：**
 - 规则引擎：段落级匹配率 < 0.4 判定为删除，删除超 30% 字符数标记为 critical
 - LLM 判断：评估被删除内容是否包含有效信息
- **误改（mis_edit）检测：**
 - 规则引擎：字符级 diff 提取数值变化，变化幅度 > 10% 标记为 critical
 - LLM 判断：评估修改是否改变了原文含义
- **瑕疵结构化输出：**

```
{
  "category": "mis_edit",
  "severity": "critical",
  "description": "营业收入数值被错误修改：120万元→12万元，丢失一个数量级",
  "location": {
    "segment_id": "before_1",
    "start_char": 12,
    "end_char": 24,
    "snippet": "营业收入为120万元"
```

```
},  
"suggestion": "恢复原始数值或标注修改原因"  
}
```

4.3 可读性与结构质量评估

目标： 标题树合理性、段落连贯性、表格可读性。

实现方式：

- **Prompt 维度定义：** "结构完整性" (权重 0.15) + "可读性" (权重 0.15)
- **规则引擎：** 检测 Markdown 表格行/列丢失、列表层级破坏、标题层级错乱
- **格式豁免：** 纯标点/空格/段落对齐调整不扣语义分 (防止格式优化被误罚)

4.4 锚点级瑕疵定位

目标： 评估结果均可回溯到具体位置。

实现方式：

- **对齐模块：** `build_anchored_text()` 将前后文本按段落对齐，用 `difflib.SequenceMatcher` (阈值 0.4) 匹配段落，加上 `[Before N]/[After N]` 锚点标记
- **定位精度：** 每个瑕疵输出 `segment_id + start_char + end_char + snippet`
- **准确率计算：** `compute_anchor_accuracy()`，snippet 重叠 ≥ 4 字符 + start_char 容差 ≤ 10 字符

4.5 评分稳定性与可解释性

目标： 降低评分波动、给出判定理由。

实现方式：

- **稳定性验证** (`app/stability.py`):
 - 同一输入跑 N 次 (默认 5 次, temperature=0.0)
 - 计算每维度均值、方差、标准差
 - 方差 < 0.005 判定为稳定
 - 瑕疵投票机制：按 (类别, 片段前30字符) 分组，多数投票决定严重程度
- **可解释性：**
 - 每个维度输出 `reason` 字段 (判定理由)
 - 每个瑕疵输出 `description` (问题描述) + `suggestion` (修改建议)
 - 置信度计算：三因子加权 (diff 一致性 + reason 完整性 + 规则一致性)
- **临界区自动重采样：** 评分落在 0.75-0.85 时自动多跑 2 次取平均，减少边界误判

4.6 可复现性

目标： 固定策略下，相同输入始终得到相同输出。

实现方式：

- SHA256 哈希生成可复现令牌：SHA256(前后文本 + 温度 + 模型 + Prompt版本 + 规则版本 + Profile)
- 相同输入在固定策略下始终生成相同令牌
- 支持按令牌查找历史评估结果 (storage.py)

五、研究亮点：评分稳定化 + 一致性校准

这是本课题的核心研究亮点，给出了可验证的量化证据。

5.1 一致性校准

方法： 在 34 条人工标注数据集上，对比 LLM 评分与人工评分，计算 5 项指标。

校准指标：

指标	说明	目标值
Pearson r	线性相关系数	≥ 0.8
Spearman ρ	秩相关系数	≥ 0.8
MAE	平均绝对误差	尽量低
RMSE	均方根误差	尽量低
一致率	误差 ≤ 0.1 的比例	$\geq 80\%$

校准过程（数据驱动的迭代优化）：

轮次	操作	Pearson r
基线	首次校准	0.61
第一轮	强化数值敏感性	0.72
第二轮	增加格式豁免条款	0.78
第三轮	提高过度清洗权重	≥ 0.8

偏差归因方法： 对高偏差样本逐条分析，将误判归纳为三类（数值敏感性不足 / 格式优化误罚 / 过度清洗识别不足），每轮定向修改 Prompt 中对应的规则。

5.2 评分稳定化

方法： 同一输入执行 N 次评估 (temperature=0.0)，计算方差。

稳定化机制：

- 低温度 (temperature=0.0) 减少随机性
- 多次采样取平均 (stabilize 模式)
- 瑕疵投票：多数投票决定严重程度，避免单次波动
- 临界区重采样：边界分数自动多跑 2 次

5.3 抗偏置

偏置检测：

偏置类型	检测方法	风险阈值
长度偏置	前后文本长度比	<0.3 高风险，<0.6 中风险
位置偏置	瑕疵前后半部分分布	>80% 集中 = 偏置

偏置缓解：

- 抗偏置 Prompt 指令自动注入（长度无关/位置无关/格式无关/领域无关）
- 偏置缓解得分 = 维度分数标准差 × 0.5 + 长度因子 × 0.5

六、技术指标与验收对照

指标项	目标值	当前实现	状态
与人工一致性	相关性 ≥ 0.8	Pearson r ≥ 0.8（经 3 轮调优达标）	✓
评分稳定性	方差足够小	多次采样方差 < 0.005	✓
瑕疵检出	F1 ≥ 0.8	Precision/Recall/F1 已实现，基于类型+位置匹配	✓
可解释性	理由可被人工复核	每维度 reason + 每瑕疵 description + suggestion	✓
瑕疵可定位	定位准确率 ≥ 90%	snippet 重叠 + 字符容差 ≤ 10	✓
可复现	固定策略可复现	SHA256 令牌 + 历史持久化	✓

七、对外接口设计

系统作为服务被质检流水线调用，对外暴露标准 REST API。

7.1 核心接口

端点	方法	功能
/api/v1/evaluate	POST	单条评估（输入前后文本，输出评分+瑕疵）
/api/v1/batch/evaluate	POST	批量评估（上限 50 条，异步并发）
/api/v1/report/full	POST	综合验收报告（7 大模块 + I1-I8 检查）

7.2 调用示例

请求：

```
POST /api/v1/evaluate
{
  "before_text": "公司2023年营业收入为120万元，同比增长15%，净利润率维持在8.5%。",
```

```
"after_text": "公司2023年营业收入为12万元，同比增长15%，净利润率维持在8.5%。",
"evaluation_profile": "general"
}
```

响应:

```
{
  "dimensions": [
    {"dimension": "semantic_consistency", "score": 0.35, "weight": 0.35, "reason": "营业收入数值被篡改"},
    {"dimension": "factual_accuracy", "score": 0.20, "weight": 0.35, "reason": "数量级错误: 120万→12万"},
    {"dimension": "structure_integrity", "score": 0.95, "weight": 0.15, "reason": "结构完整"},
    {"dimension": "readability", "score": 0.90, "weight": 0.15, "reason": "语句通顺"}
  ],
  "overall_score": 0.42,
  "flaws": [
    {
      "category": "mis_edit",
      "severity": "critical",
      "description": "营业收入数值被错误修改: 120万元→12万元, 丢失一个数量级",
      "location": {"segment_id": "before_1", "start_char": 12, "end_char": 24},
      "suggestion": "恢复原始数值"
    }
  ],
  "verdict": "fail",
  "reproducibility_token": "a3f2b8c1...",
  "confidence": 0.92,
  "risk_level": "high"
}
```

7.3 多模型适配

支持通过请求参数切换评估模型:

模型	适配器	说明
DeepSeek Chat	DeepSeekAdapter	默认模型
Mimo 2.5 Pro	MimoAdapter	小米模型
GPT-4o	GPTAdapter	OpenAI 模型

7.4 差异化评估策略 (Profile)

Profile	适用场景	特殊规则
general	通用文本	默认四维度评分

Profile	适用场景	特殊规则
government_notice_strict	政府公告	日期/期限/阈值/义务范围 严格检查
legal_strict	法律文书	责任主体/义务/条件/法律后果 严格检查

八、交付物清单

交付物	说明
可运行的评估智能体	FastAPI 后端 + Streamlit 演示 + HTML 前端
标准 REST API	15 个端点，供质检流水线调用
评估数据集	eval_dataset.json（34 条人工标注）
金标准数据集	gold_dataset_v1.json（34 条，用于校准器拟合）
综合验收报告	7 大模块集成 + I1-I8 验收标准自动判定
校准报告	Pearson/Spearman/MAE/RMSE/一致率
稳定性报告	多次采样方差 + 瑕疵投票结果
测试用例	端到端测试 + 边界测试 + 异常测试

九、总结

本课题围绕"LLM-as-Judge 裁判可信度"这一核心问题，构建了一个面向治理前后比对场景的评估智能体。系统的核心贡献在于：

- 1. **双通道瑕疵检测**：规则引擎（确定性）+ LLM 语义判断（灵活性）互为补充，数值变化等关键瑕疵不遗漏
- 2. **数据驱动的 Prompt 调优**：通过"偏差归因→定向修改→校准验证"的迭代循环，Pearson r 从 0.61 提升至 ≥ 0.8
- 3. **评分稳定化机制**：多次采样 + 瑕疵投票 + 临界区重采样，方差 < 0.005
- 4. **锚点级可追溯**：每个瑕疵精确定位到 segment + 字符位置，支持人工复核
- 5. **可复现性保障**：SHA256 令牌确保固定策略下结果一致
- 6. **可作为服务调用**：标准 REST API，支持批量评估、多模型切换、差异化 Profile

系统已完成核心功能开发与验收测试，具备被质检流水线集成调用的能力。